机器学习

一、概述

掌握实际算法

一、应用

1、模式识别（抽象概念）

定义：样本数据提取 pattern，并分类、回归、聚类（预测）

步骤：1、特征提取；2、模型构建 3、评估：

- 分类：分类：二分→多分
  样本：低维→高
  模型：线→非线
- 回归：一组随机变量（y_i）与另一组（x_i）的关系
- 聚类：分组；无监督：适合、后定语义 no table

2、特征提取：即降维，d维样本中提取k维的新集合

3、数据生成：m源于分布q(x)，在不知道q(x)下造相似样本

4、机器学习：海量数据 5、人工智能

二、几个概念

1、样本空间，标记空间：

特征变量（n维）⟶ 特征向量

2、数据集合：训练集 验证集 测试集

①

3、张量：a kind of 数据储存结构；n+1 张量是用 n阶张 + 1个索引

4、假设空间（H）

学习的结果：$f: X\to Y$ or $P(Y|X)$

选择H中最好的g近似于f，学习 g(x,w) 就是学习参数 w

② 5. 选择学习策略

① 经验风险最小策略：

损失函数 L(w)：

总样本 MSE

③ ② 结构风险最小：正则化约束

泛化能力：指对新样本的适应，反目夹　过拟合！

原则：选 easy 的

6. 优化参数的算法　7. 机器学习流程

L(w)

三、技术系统分类

I：分类标记：

II：数据动态性：

III：　IV

1、有监督/无

2、基于实例

3、生成判别模型：line

4、强化学习

第二讲　模型选择与评估

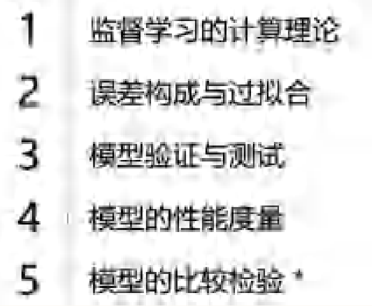

1 监督学习的计算理论
2 误差构成与过拟合
3 模型验证与测试
4 模型的性能度量
5 模型的比较检验 *

一、

Y：值
标签

任务不同，维数不同

有监
无监
半监
自监

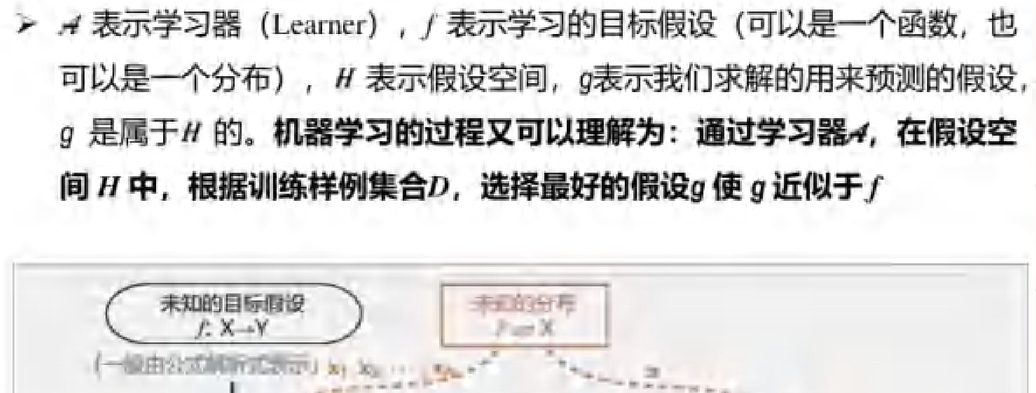

➢ 𝒜 表示学习器（Learner），f 表示学习的目标假设（可以是一个函数，也可以是一个分布），H 表示假设空间，g表示我们求解的用来预测的假设，g 是属于H 的。**机器学习的过程又可以理解为：通过学习器𝒜，在假设空间 H 中，根据训练样例集合D，选择最好的假设g 使 g 近似于 f**

问题一：选g $E_{out}(g) \approx E_{in}(g)$
可实现???

问题二：

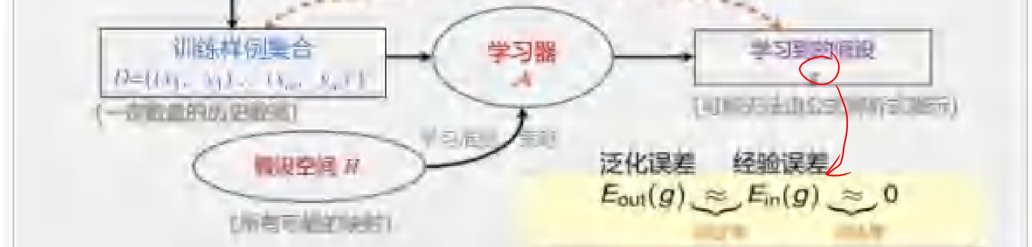
训练样例集合
$D=\{(x_1,y_1),\ldots,(x_m,y_m)\}$
(一定数量的历史数据)
学习器 A
学习到的假设
假设空间 H
(所有可能的映射)
学习算法
泛化误差
经验误差
$E_{out}(g) \approx E_{in}(g) \approx 0$

泛化力

1、有效假设

2、VC维：参数，H、k

① 增长函数 $\Pi_H(m)$ 最大可能数 2^m

② H散列　D被H散列了

③ k中断点　当 $\Pi_H(m)<2^m$ 无法散列

④ VC维：$VC(H)=k-1$，k为H的中断点

H为 R^d 则 $VC(H)=d+1$

3、可学习的前提条件

4、VC维的意义

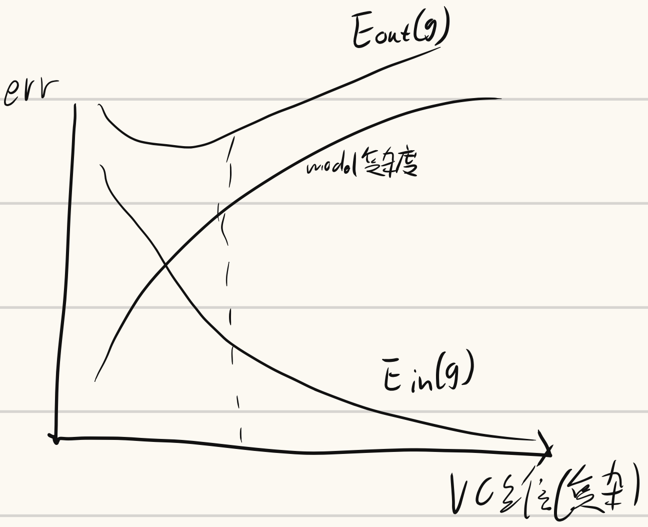

线性模型 ← 降维后

二、g选择评估

1、误差分解

误差 {
偏差：$\mu - \hat{X}$
方差：稳定性 D_{new}
噪声：

平均误差

$E_D[(\hat{y}_D-y_D)^2] = \underbrace{方差+偏差}_{most}+噪声$

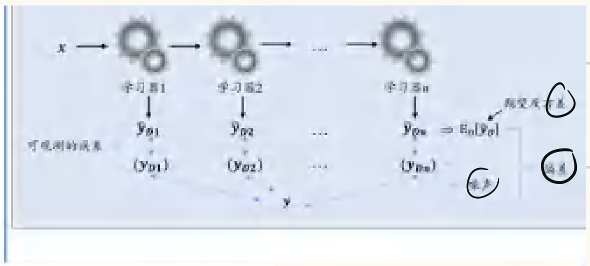
x
学习器1
学习器2
学习器n
$\hat{y}_{D1}$
$\hat{y}_{D2}$
$\hat{y}_{Dn}$
$\Rightarrow E_D[\hat{y}_D]$
期望及方差
可观测的结果
(y_{D1})
(y_{D2})
(y_{Dn})
y
噪声
偏差

$= (E_D[\hat{y}_D]-y)^2$

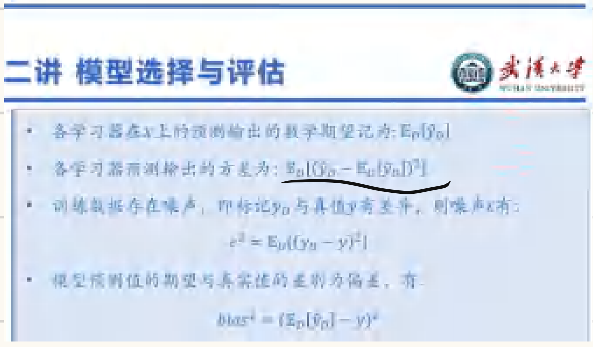

二讲 模型选择与评估

- 各学习器在x上的预测输出的数学期望记为：$E_D[\hat{y}_D]$
- 各学习器预测输出的方差为：$E_D[(\hat{y}_D - E_D[\hat{y}_D])^2]$
- 训练数据存在噪声，即标记y_D与真值y有差异，则噪声ε有：

$$\varepsilon^2 = E_D[(y_D - y)^2]$$

- 模型预测值的期望与真实值的差别为偏差，有：

$$bias^2 = (E_D[\hat{y}_D] - y)^2$$

5 线性回归的性能度量

→第二讲

2.

欠拟合	过拟合:
均佳, 过easy	不普适
偏差↑	方差↓
Bias	Variance

3. 三元权衡 { 复杂度
数据规模偏差
泛化误差

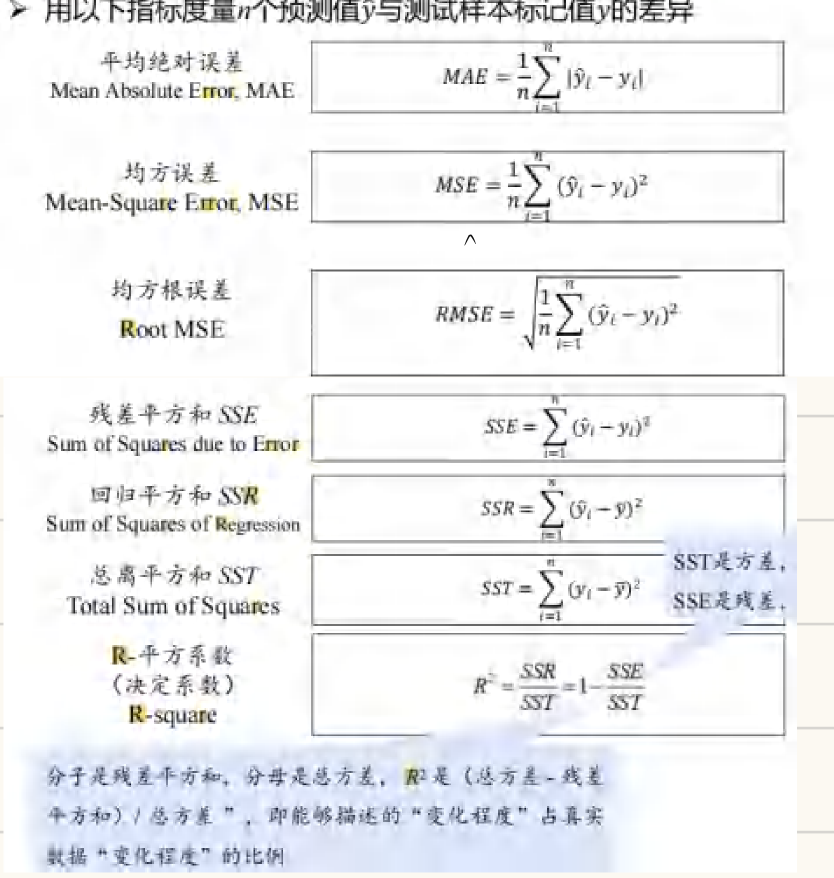

➤ 用以下指标度量n个预测值$\hat{y}$与测试样本标记值y的差异

平均绝对误差 Mean Absolute Error, MAE	$MAE = \frac{1}{n}\sum_{i=1}^{n} \lvert \hat{y}_i - y_i \rvert$
均方误差 Mean-Square Error, MSE	$MSE = \frac{1}{n}\sum_{i=1}^{n} (\hat{y}_i - y_i)^2$
均方根误差 Root MSE	$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (\hat{y}_i - y_i)^2}$
残差平方和 SSE Sum of Squares due to Error	$SSE = \sum_{i=1}^{n} (\hat{y}_i - y_i)^2$
回归平方和 SSR Sum of Squares of Regression	$SSR = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$
总离平方和 SST Total Sum of Squares	$SST = \sum_{i=1}^{n} (y_i - \bar{y})^2$
R-平方系数 （决定系数） R-square	$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$

SST是方差，
SSE是残差，

分子是残差平方和，分母是总方差，R^2是（总方差 - 残差平方和）/ 总方差"，即能够描述的"变化程度"占真实数据"变化程度"的比例

y_i 真值
$\hat{y}_i$ 估值
$\bar{y}$ 均值

三 模型验证:

☆ 会算

训练 / 验证, 测试
参数　测 超参数 人工设定

1. 留出法, 分层采样; 充分

2. K折交叉验证 ☆

3. 自助采样法

四. 模型的性能评估

1. 分类任务: 混淆矩阵

		正	负
真实	正	TP	FN
	负	FP	TN

几个概念:

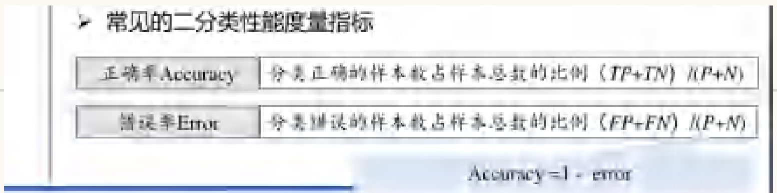

➤ 常见的二分类性能度量指标

正确率Accuracy	分类正确的样本数占样本总数的比例 $(TP+TN)/(P+N)$
错误率Error	分类错误的样本数占样本总数的比例 $(FP+FN)/(P+N)$

Accuracy =1 - error

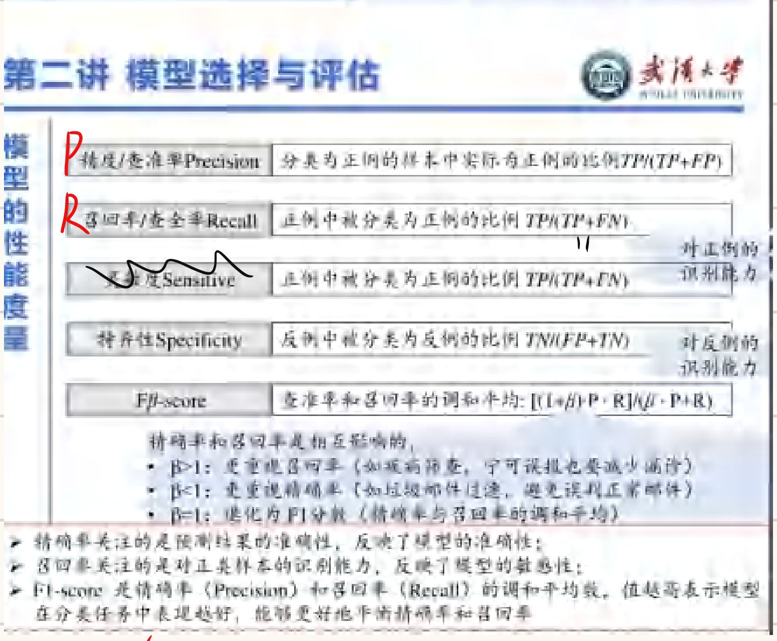

第二讲 模型选择与评估

模型的性能度量

P 精度/查准率Precision	分类为正例的样本中实际为正例的比例TP/(TP+FP)	
R 召回率/查全率Recall	正例中被分类为正例的比例 TP/(TP+FN)	对正例的识别能力
~~灵敏度~~Sensitive	正例中被分类为正例的比例 TP/(TP+FN)	
特异性Specificity	反例中被分类为反例的比例 TN/(FP+TN)	对反例的识别能力
Fβ-score	查准率和召回率的调和平均: [(1+β)·P · R]/(β · P+R)	

精确率和召回率是相互影响的,
- β>1: 更重视召回率(如疾病筛查,宁可误报也要减少漏诊)
- β<1: 更重视精确率(如垃圾邮件过滤,避免误判正常邮件)
- β=1: 退化为F1分数(精确率与召回率的调和平均)

- 精确率关注的是预测结果的准确性,反映了模型的准确性;
- 召回率关注的是对正类样本的识别能力,反映了模型的敏感性;
- F1-score 是精确率(Precision)和召回率(Recall)的调和平均数,值越高表示模型在分类任务中表现越好,能够更好地平衡精确率和召回率

1. PR曲线 确定学习器性能　　绘过程

①概念排序 ②↓ 预测结果阈值

看面积大

看45°交点

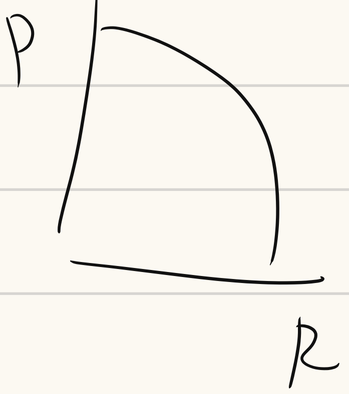

2. ROC曲线

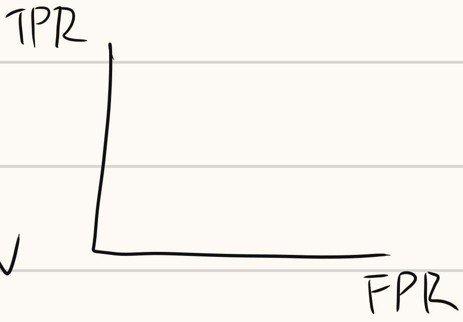

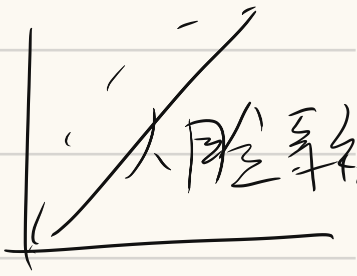

纵轴:真正例率 召回率 $\frac{TP}{TP+FN}$

横轴:假正例率 $\frac{FP}{TN+FP}$

2. 回归问题

均方误差 MSE

RMSE

SST=SSR+SSE　$R^2=\frac{SSR}{SST}\to 1$

与Loss的区别

测试样本的误差

五 模型的假设检验:

第三章 贝叶斯分类器 模型

监督学习模型 标签

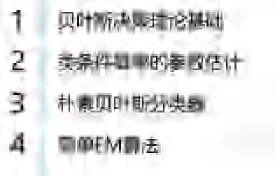

1 贝叶斯决策理论基础
2 类条件概率的参数估计
3 朴素贝叶斯分类器
4 简单EM算法

一、

最小错

1、有先验概率

x属于c_k类的概率：

$$\overset{\text{后验概率}}{P(c_k|x)} = \frac{P(x|c_k)\overset{\text{类条件}}{\uparrow}P(c_k) \rightarrow \text{先验}}{\sum P(x|c_i)P(c_i)} \rightarrow \text{证据：全概}$$

↓ 新样本x出现属于c_k类的概率

2、错误率：(二分类)

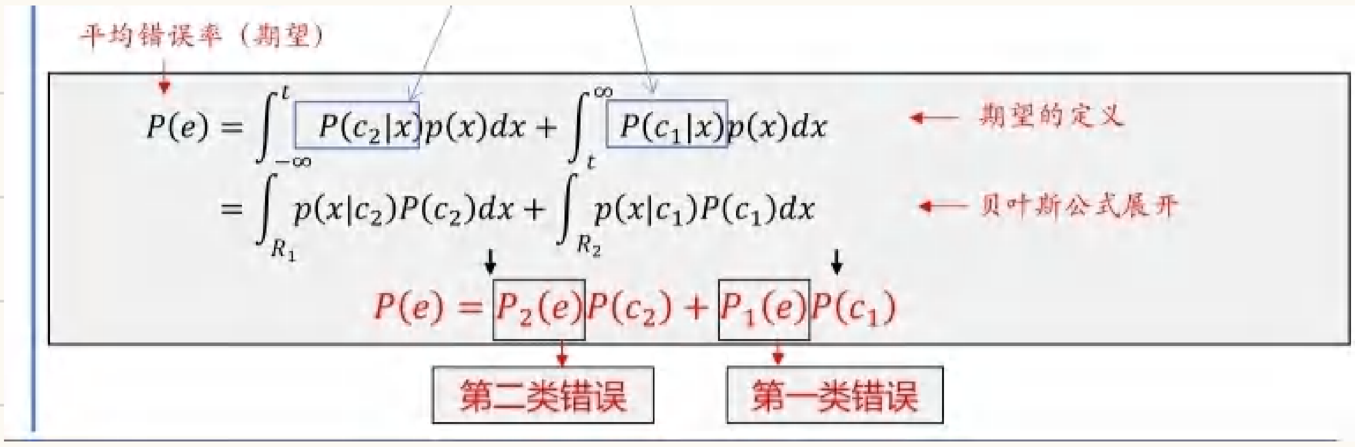

平均错误率（期望）

$$P(e) = \int_{-\infty}^{t} \boxed{P(c_2|x)}p(x)dx + \int_{t}^{\infty} \boxed{P(c_1|x)}p(x)dx \quad \leftarrow \text{期望的定义}$$

$$= \int_{R_1} p(x|c_2)P(c_2)dx + \int_{R_2} p(x|c_1)P(c_1)dx \quad \leftarrow \text{贝叶斯公式展开}$$

$$P(e) = \underbrace{\boxed{P_2(e)}}_{\text{第二类错误}}P(c_2) + \underbrace{\boxed{P_1(e)}}_{\text{第一类错误}}P(c_1)$$

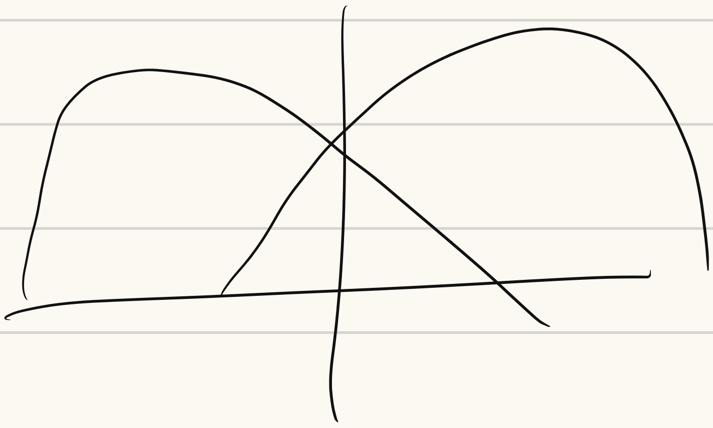

基于最小错误率

小风险

判决函数：最小风险

① 构造二分判决函数

② 条件风险：$R(\alpha_i|x) = \sum \lambda_{ij} P(c_j|x)$ ← 后验贝叶斯

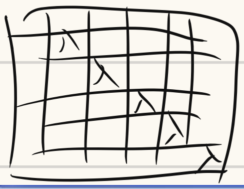

(基于最小风险)

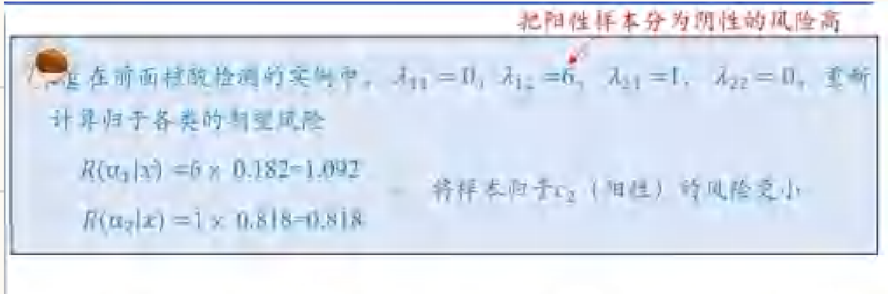

把阳性样本分为阴性的风险高

假定在前面细胞检测的实例中，$\lambda_{11}=0$，$\lambda_{12}=6$，$\lambda_{21}=1$，$\lambda_{22}=0$，重新计算归于各类的期望风险

$R(\alpha_1|x)=6\times 0.182=1.092$

$R(\alpha_2|x)=1\times 0.818=0.818$

将样本归于c_2（阳性）时风险更小

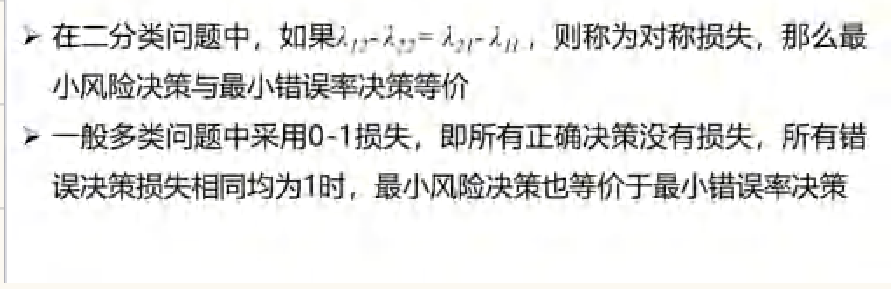

- 在二分类问题中，如果$\lambda_{12}-\lambda_{22}=\lambda_{21}-\lambda_{11}$，则称为对称损失，那么最小风险决策与最小错误率决策等价
- 一般多类问题中采用0-1损失，即所有正确决策没有损失，所有错误决策损失相同均为1时，最小风险决策也等价于最小错误率决策

$$\boxed{类条件概率} \to \boxed{参数} < \boxed{\begin{matrix}极大似然\\贝叶斯\end{matrix}}$$

2. 参数

似然

1、对类条件概率 $P(X|Y=c_k)$ 的参数估计

例：①先验概率 ②类条件概率

↓

极大似然估计

$$L(\theta_{c_k}) = L(\theta_{c_k}; x_1, \dots) = \prod p(\theta_{c_k}; x_i)$$

求解 $\hat{\theta}_{c_k}$ ①连乘 ②取对 ③导数为0

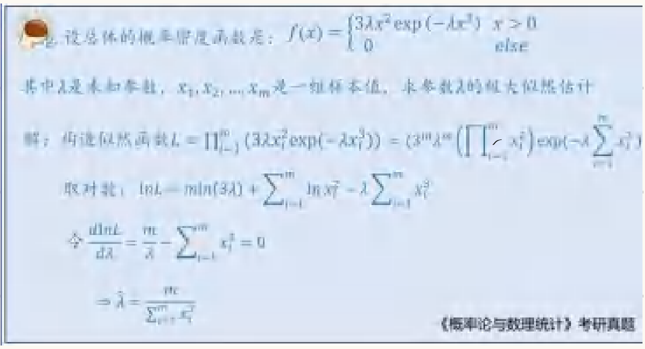

设总体的概率密度函数是：$f(x)=\begin{cases}3\lambda x^2\exp(-\lambda x^3) & x>0\\ 0 & else\end{cases}$

其中λ是未知参数，$x_1, x_2, \dots, x_m$是一组样本值，求参数λ的极大似然估计

解：构造似然函数 $L=\prod_{i=1}^m(3\lambda x_i^2\exp(-\lambda x_i^3)) = (3^m\lambda^m(\prod_{i=1}^m x_i^2)\exp(-\lambda\sum_{i=1}^m x_i^3)$

取对数：$\ln L = m\ln(3\lambda)+\sum_{i=1}^m \ln x_i^2 - \lambda\sum_{i=1}^m x_i^3$

令 $\frac{d\ln L}{d\lambda}=\frac{m}{\lambda}-\sum_{i=1}^m x_i^3=0$

$\Rightarrow \hat{\lambda}=\frac{m}{\sum_{i=1}^m x_i^3}$

《概率论与数理统计》考研真题

2、常见的MLE：

① 正态：估 μ 和 σ

② 伯努利：1

2.贝叶斯

参数 θ_{c_k} 服从 $\pi(\theta_{c_k})$ 的分布（参数的分布）

最后用：极大后验估计(MAP)

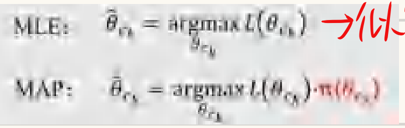

MLE: $\hat{\theta}_{c_k} = \underset{\theta_{c_k}}{\operatorname{argmax}} L(\theta_{c_k})$ → 似然

MAP: $\hat{\theta}_{c_k} = \underset{\theta_{c_k}}{\operatorname{argmax}} L(\theta_{c_k})\cdot\pi(\theta_{c_k})$ ：作用 正则化（防过拟合）

$\pi(\theta_{c_k})$ <

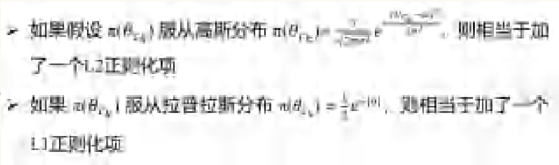

- 如果假设$\pi(\theta_{c_k})$服从高斯分布$\pi(\theta_{c_k})=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(\theta_{c_k}-\mu)^2}{2\sigma^2}}$，则相当于加了一个L2正则化项
- 如果$\pi(\theta_{c_k})$服从拉普拉斯分布$\pi(\theta_{c_k})=\frac{1}{2}e^{-|\theta|}$，则相当于加了一个L1正则化项

决策界方程 $\overbrace{(\underset{\pi}{同先验}, \underset{\Sigma}{同方差})}^{前提}$ $\xrightarrow{得}$ 线性决策界

3. 朴素贝叶斯 独立

↳ ：条件独立性假设

e.g. ①分别统计：

$$P(c_k|x) = \frac{P(X=x|Y=c_k)P(Y=c_k)}{P(x)} = \frac{P(c_k)}{P(x)}\prod P(x^{(i)}|c_k)$$

(a) $P(Y=1|X)=\frac{P(Y=1)}{P(X)}\cdot\frac{1}{\sqrt{2\pi}5}e^{-\frac{(x-140)^2}{2\times25}}\cdot\frac{1}{\sqrt{2\pi}4}e^{-\frac{(x-30)^2}{2\times16}}$

$P(Y=0|X)=\frac{P(Y=0)}{P(X)}\cdot\frac{1}{\sqrt{2\pi}6}e^{-\frac{(x-100)}{2\times36}}\cdot\frac{1}{\sqrt{2\pi}3}e^{-\frac{(x-25)}{2\times9}}$

当 $X=(132,28)$ 时：$\frac{P(Y=1|X)}{P(Y=0|X)}=\frac{0.08}{0.92}\frac{16}{20}e^{-\frac{1}{2}\left[\left(\frac{64}{100}+\frac{4}{32}\right)+\left(\frac{32}{36\times2}+\frac{0}{18}\right)\right]}=0.04<1$

(b) 由 a：后验全根据：判健康

(c) $\frac{P(Y=1|X)}{P(Y=0|X)}=\frac{0.15}{0.85}\cdot\frac{16}{20}e^{-\frac{1}{2}\left[\left(\frac{64}{100}+\frac{4}{32}\right)+\left(\frac{32}{36\times2}+\frac{0}{18}\right)\right]}=0.086$

不变

4、EM算法 一种

有隐变量 z，用 E, Max 算法

流程：

$Q(x)\longrightarrow P(x)$

初值 $\hat{\mu}$ σ

$\hat{Q}\to\mu$ σ 迭代，收敛

$Q\to\hat{\mu}$ $\hat{\sigma}$

算法：X样本 $=(x_1,x_2\dots x_m)$ 隐变量 $z=(z_1\dots z_n)$

$z\to\hat{\theta}$

z的相关，超参

$P(x_i;\theta)=\sum_{j=1}^{n}P(x_i,z_j;\theta)$

由 jensen：$\frac{P(x_i z_j;\theta)}{Q_i(z_j)}=C_i$

迭代：

似然函数：$L(\theta\ z)$

优化目标：$\hat{\theta}$, z：

的分布：$Q(\theta,\hat{\theta}^{(k)})=$

(期望最大化 最优参数 $\hat{\theta}$)

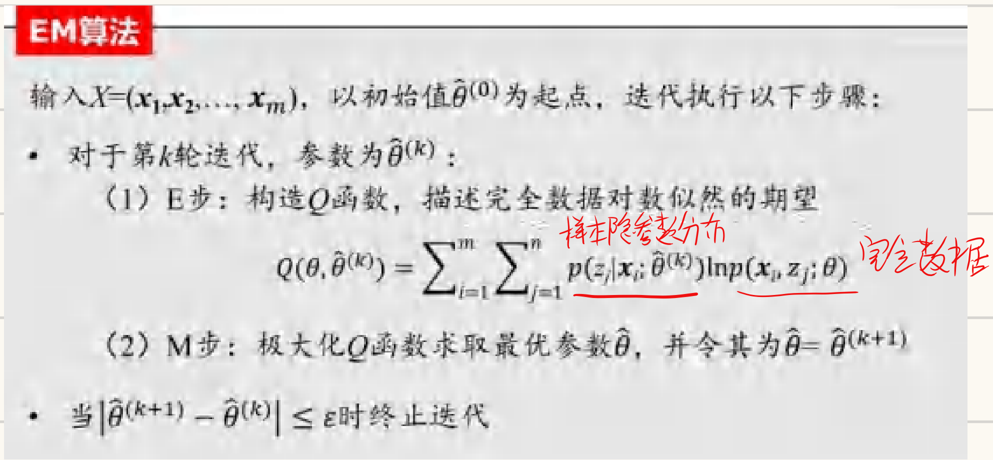

EM算法

输入 $X=(x_1,x_2,\dots,x_m)$，以初始值 $\hat{\theta}^{(0)}$ 为起点，迭代执行以下步骤：

- 对于第 k 轮迭代，参数为 $\hat{\theta}^{(k)}$：
  - （1）E步：构造 Q 函数，描述完全数据对数似然的期望

    样本隐含参数分布

    $$Q(\theta,\hat{\theta}^{(k)})=\sum_{i=1}^{m}\sum_{j=1}^{n}\underline{p(z_j|x_i;\hat{\theta}^{(k)})}\ln\underline{p(x_i,z_j;\theta)}$$

    完全数据对数似然
  - （2）M步：极大化 Q 函数求取最优参数 $\hat{\theta}$，并令其为 $\hat{\theta}=\hat{\theta}^{(k+1)}$
- 当 $|\hat{\theta}^{(k+1)}-\hat{\theta}^{(k)}|\le\varepsilon$ 时终止迭代

E-Step

初始化：$\hat{\theta}_A^{(0)}$ $\hat{\theta}_B^{(0)}$ 则 $P(x_i;\theta)=$

第一种硬币：$P(x_1;\hat{\theta}^{(0)})=$

$P(z_1|x_1;\hat{\theta}^{(0)})=$

$P(z_2|x_1;\hat{\theta}^{(0)})=$

第1次迭代概率: 2: $P_A(z_1|x_2;\tilde\theta^{(0)})$ P_B

3: $P_A(z_1|x_3;\tilde\theta^{(0)})$ P_B

4: $P_A(z_1|x_4;\tilde\theta^{(0)})$ P_B

5: $P_A(z_1|x_5;\tilde\theta^{(0)})$ P_B

此时的Q函数: $\underline{Q(\theta,\tilde\theta^{(0)})} = P_A \overbrace{\ln(\theta_A^5(1-\theta_A)^5)}^{1} + \overbrace{P_B \ln(\theta_B^5(1-\theta_B)^5)}^{-}$

一个期望

M-step

$\frac{\partial Q}{\partial \theta_A}$ 解 $\theta_A^{(1)}$ $\frac{\partial}{\partial \theta_B}$ 解 $\theta_B^{(1)}$

迭代条件 $|\theta_A^{(k+1)} - \theta_A^{(k)}| < \varepsilon$ 收敛

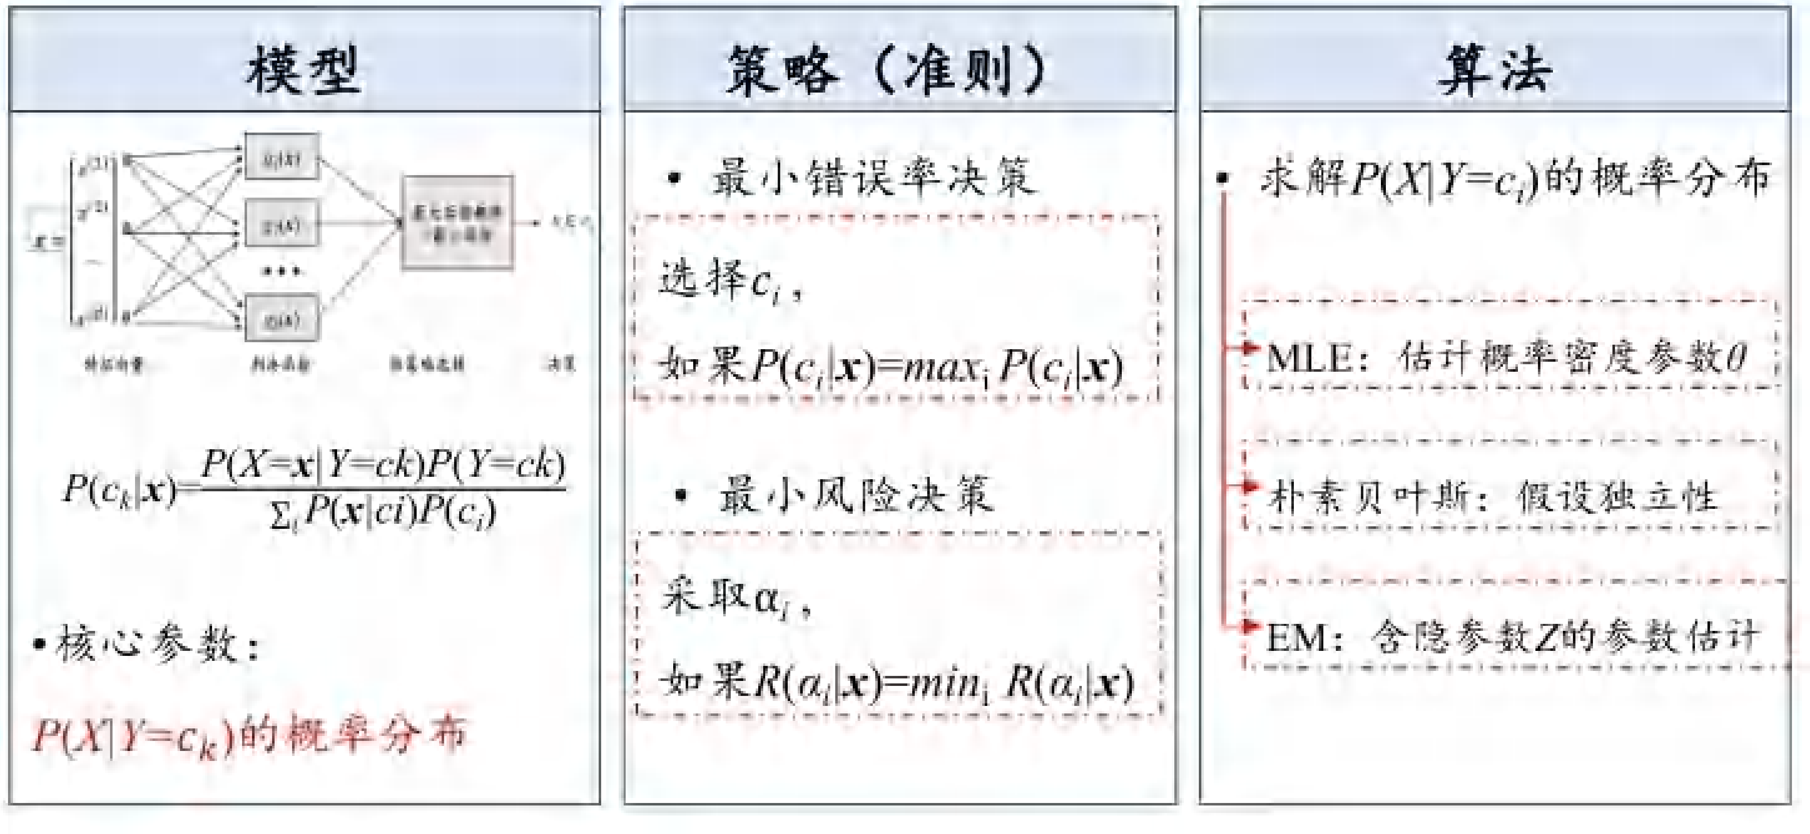

模型

$$P(c_k|\mathbf{x})=\frac{P(X=\mathbf{x}|Y=ck)P(Y=ck)}{\Sigma_i P(\mathbf{x}|ci)P(c_i)}$$

- 核心参数：

$P(X|Y=c_k)$的概率分布

策略（准则）

- 最小错误率决策

选择c_i，

如果$P(c_i|\mathbf{x})=max_j P(c_j|\mathbf{x})$

- 最小风险决策

采取α_i，

如果$R(\alpha_i|\mathbf{x})=min_j R(\alpha_j|\mathbf{x})$

算法

- 求解$P(X|Y=c_i)$的概率分布
  - MLE：估计概率密度参数θ
  - 朴素贝叶斯：假设独立性
  - EM：含隐参数Z的参数估计

第四章 线性模型

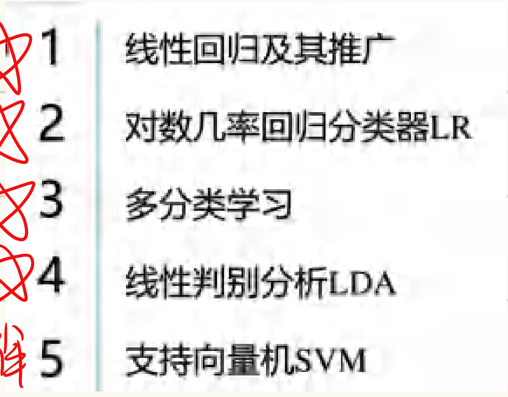

☆ 1 线性回归及其推广
☆ 2 对数几率回归分类器LR
☆ 3 多分类学习
☆ 4 线性判别分析LDA
理解 5 支持向量机SVM

回归 分类 聚类

1. 线性回归 (目的: 解w参数)

$y = x_i^T w + w_0 = Xw$

学习准则 $\boxed{\text{MSE作 代价}} = \frac{1}{m}\sum^{m}(\hat{y}_i - y_i)^2$

优化算法 $L(w) = (y - Xw)^T(y - Xw)$ 求导出参

X^TX可逆 最小二乘

X^TX不可逆 梯度下降法

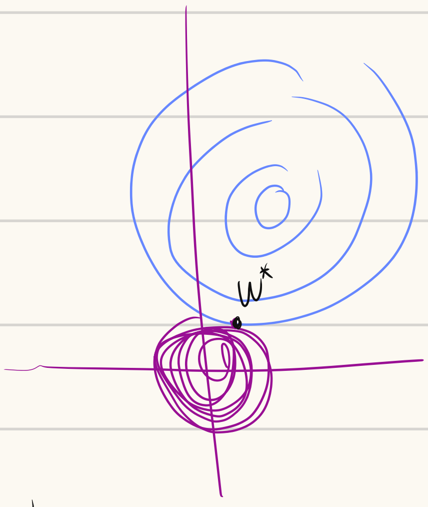

代价函数 $L(w) = \frac{1}{2m}\sum_{i=1}^{m}(\hat{y} - y)^2$

算梯度 $L(w)$函数↓最快的方向

确定η学习率(超参步长), 找极值

$$w^{(i+1)} \leftarrow w^{(i)} - \eta \cdot \frac{\partial L(w^{(i)})}{\partial w^{(i)}}$$

初始 w
算预测 $\hat{y}$
算 $L(w)$
算梯度
更新参数 $w^{(i+1)} = w^{(i)} - \eta \cdot \frac{\partial L(w)}{\partial w^{(i)}}$

正则化: 防过拟合

岭回归 L_2: 平方和, 鼓励小参数

$L(w) = \frac{1}{2n}\left[\sum(\hat{y} - y)^2 + \underset{\text{超参}}{\underline{\lambda}}\sum^{d} w_j^2\right]$

$w^* = (X^TX + \lambda I)^{-1}X^Ty$ 闭式解

可逆 最小二乘

梯度下降: $w^{(i+1)} = w^{(i)} - \eta\left(\frac{\partial L(w)}{\partial w^{(i)}} + \frac{\lambda}{m}w_k^{(i)}\right)$

Lasso回归 L_1: 绝对值, (道理一样, 换$|w|$)

区别 L_2无法舍参, L_1可舍, 权为0

广义线性回归

y在指数尺度上变化, 基函数 $\phi(x) \xrightarrow{\text{映射}}$ 线性

多项式回归

展开为低次,)

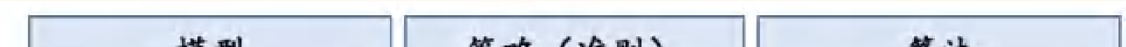

模型	策略（准则）	算法

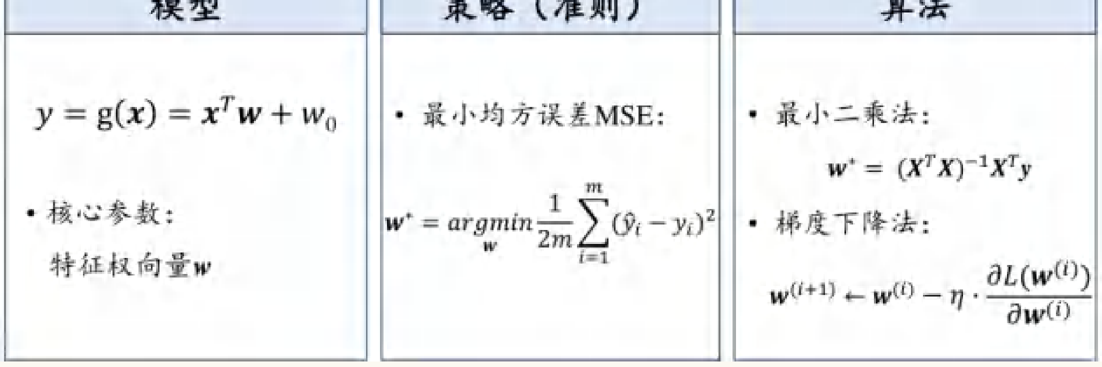

模型	策略（准则）	算法
$y = g(x) = x^T w + w_0$ • 核心参数： 特征权向量w	• 最小均方误差MSE： $w^* = \underset{w}{argmin}\frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2$	• 最小二乘法： $w^* = (X^TX)^{-1}X^Ty$ • 梯度下降法： $w^{(i+1)} \leftarrow w^{(i)} - \eta \cdot \frac{\partial L(w^{(i)})}{\partial w^{(i)}}$

logistic回归

$y = \frac{1}{1+e^{-z}}$

2、对数几率回归分类器LR

用于分类，but 基于广义线回归 线性二分类器

x 回归后验概率：$\hat{y}_i = P(c_1|x_i)$

① 线性回归：$\boxed{z_i = x_i' w + w_0} \rightarrow$ 决定了正确率，

② logistic 找联系函数 → 线性器：

Logistic映射为 $y = P(c_1|x_i)$（后验概率）

$z = x' w + w_0$ 为决策界方程

$z = 0$ 时 $P = 0.5$ 为决策界

$z = \ln\frac{y}{1-y}$ 几率

学习准则：$L(w) = \prod_{i=1}^{n}(P(x_i))^{y_i}(1-P(x_i))^{1-y_i}$

其中 $P(x) = P(c_1|x)$ 是 $\frac{1}{1-e^{-z}}$ 构造的

LR模型优化函数：“二分类交叉熵

交叉熵损失：非MSE：原因：非线性模型MSE非凸，不找最优解

$$L(w) = -\sum_{i=1}^{n}[y_i \cdot (x_i' w + w_0) - \ln(1+e^{x_i' w + w_0}) + L_2正则化]$$

优化算法： 梯度下降

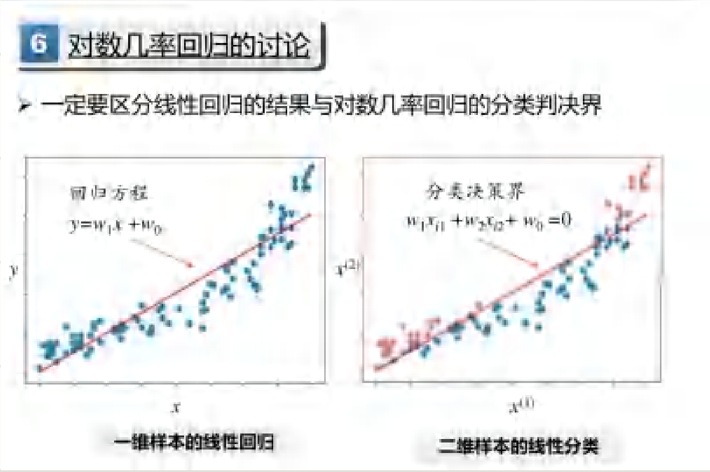

6 对数几率回归的讨论

➢ 一定要区分线性回归的结果与对数几率回归的分类判决界

一维样本的线性回归　　二维样本的线性分类

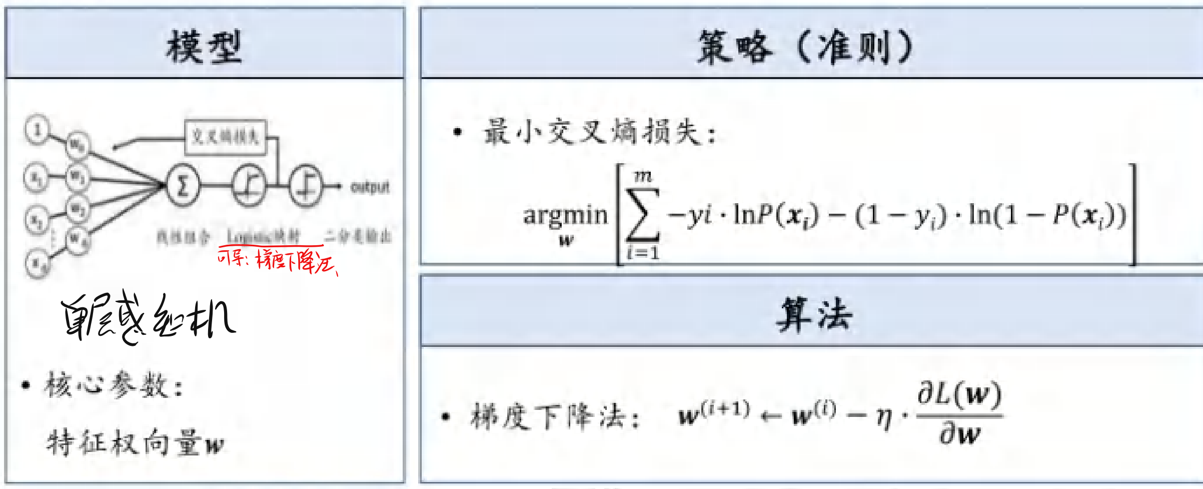

模型	策略（准则）
单层感知机 • 核心参数： 特征权向量w	• 最小交叉熵损失： $\underset{w}{argmin}\left[\sum_{i=1}^{m} -yi \cdot \ln P(x_i) - (1-y_i) \cdot \ln(1-P(x_i))\right]$
	算法
	• 梯度下降法：$w^{(i+1)} \leftarrow w^{(i)} - \eta \cdot \frac{\partial L(w)}{\partial w}$

1
x_1
x_2
x_d
w_0
w_1
w_2
w_d
交叉熵损失
Σ
output
线性组合
Logistic映射
二分类输出

可导：梯度下降法，

3.多分类学习

1. 多次二分类 → 多分类

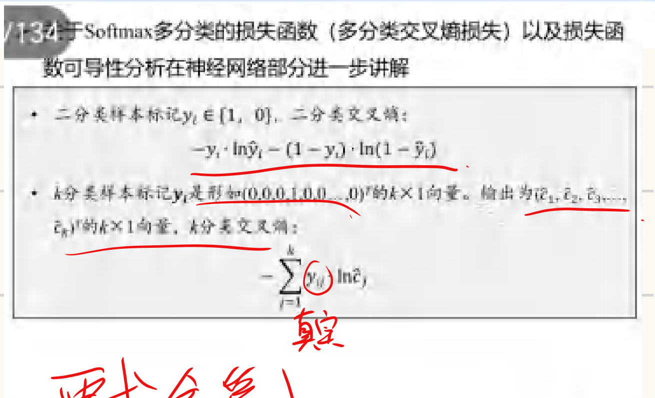

/134 于Softmax多分类的损失函数（多分类交叉熵损失）以及损失函数可导性分析在神经网络部分进一步讲解

- 二分类样本标记$y_i \in [1, 0]$，二分类交叉熵：
  $-y_i \cdot \ln\hat{y}_i - (1-y_i) \cdot \ln(1-\hat{y}_i)$
- k分类样本标记y_i是形如$(0,0,0,1,0,0,\ldots,0)^T$的$k \times 1$向量。输出为$(\hat{c}_1, \hat{c}_2, \hat{c}_3, \ldots, \hat{c}_k)^T$的$k \times 1$向量，$k$分类交叉熵：
  $-\sum_{j=1}^{k} y_{ij} \cdot \ln\hat{c}_j$

真实

★ 一对一 ★ 一对其余

$g_{ij}(x)>0$

$\begin{cases} g_i(x)>0 \\ g_j(x)<0 \ \forall j\neq i \end{cases}$

每一类可用单个边界与其它类分开

缺点：3类的决策界门槛、

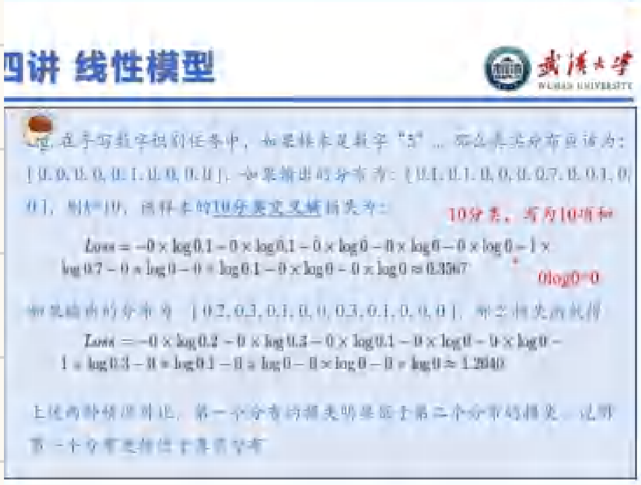
第四讲 线性模型

武汉大学 WUHAN UNIVERSITY

在手写数字识别任务中，如果样本是数字"5"，那么真实分布应该为：[0,0,0,0,0,1,0,0,0,0]，如果输出的分布为：[0.1,0.1,0,0,0,0.7,0,0.1,0,0]，则N=10，该样本的10分类交叉熵损失为： 10分类，求和10项和

$Loss = -0\times\log0.1-0\times\log0.1-0\times\log0-0\times\log0-0\times\log0-1\times\log0.7-0\times\log0-0\times\log0.1-0\times\log0-0\times\log0\approx0.3567$

$0\log0=0$

如果输出的分布为 [0.2,0.3,0.1,0,0,0.3,0.1,0,0,0]，那么损失函数将

$Loss = -0\times\log0.2-0\times\log0.3-0\times\log0.1-0\times\log0-0\times\log0-1\times\log0.3-0\times\log0.1-0\times\log0-0\times\log0-0\times\log0\approx1.2040$

上述两种情况对比，第一个分布的损失明显低于第二个分布的损失，说明第一个分布更接近于真实分布

2、softmax 函数：就是一个映射而已

神经网络用 $c-\hat{y}$

$\frac{e^{x_i}}{\sum_{i=1}^{N} e^{x_i}}$

交叉熵

Logistic 是一种 S 函数

交叉熵函数

- 二分类：$-y_i\cdot\ln\hat{y}_i-(1-y_i)\ln(1-\hat{y}_i)$ 估计
- K分类：$-\sum_{j=1}^{k} y_{ij}\cdot\ln\hat{c}_j$ 估计

计算要会★

4、线性判别分析LDA

概念速

有监督的降维 k−1维

找投影直线 + 阈值　同类尽可能近

(维投影到 k−1维上

$w^T\mu_i$

协方差 $w^T\Sigma_i w$

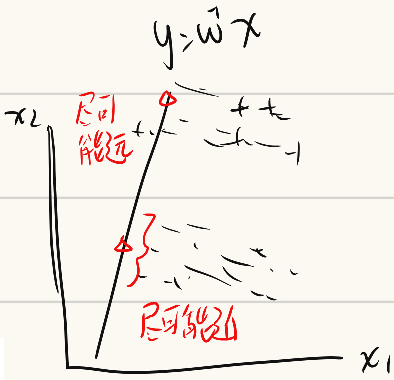

学习准则

➢ 考虑优化目标：

- 同类样例的投影点尽可能的近：两个投影的协方差和尽可能小

  S_w 类内散度矩　$w^T\Sigma_0 w + w^T\Sigma_1 w$

- 异类样例投影点尽可能的远离：各均值向量投影点距离尽可能大

  S_b 类间散度矩　$\|w^T\mu_0 - w^T\mu_1\|_2^2$　距离度量选用2范数平方

➢ 构造目标函数：最大化★

两个除一下

$$J=\frac{\|w^T\mu_0-w^T\mu_1\|_2^2}{w^T\Sigma_0 w+w^T\Sigma_1 w}=\frac{w^T(\mu_0-\mu_1)(\mu_0-\mu_1)^T w}{w^T(\Sigma_0+\Sigma_1)w}$$

$\frac{S_b}{S_w}$

优化算法：$\frac{S_b}{S_w}$的特征向量是最优，LDA判别式方法：无概率

决策界：中心间是投影点中点.

LDA监督降维，最小错误

5、支持向量机

用 $y(w^Tx+w_0)$ 的正负性来判，定义函数间隔、几何间隔

学习准则：找支持向量， $\frac{w^Tx+b}{\|w\|}$ 到两边dis相等

$=1$ 正超平面

$=0$ 决策边界

$=-1$ 负超平面

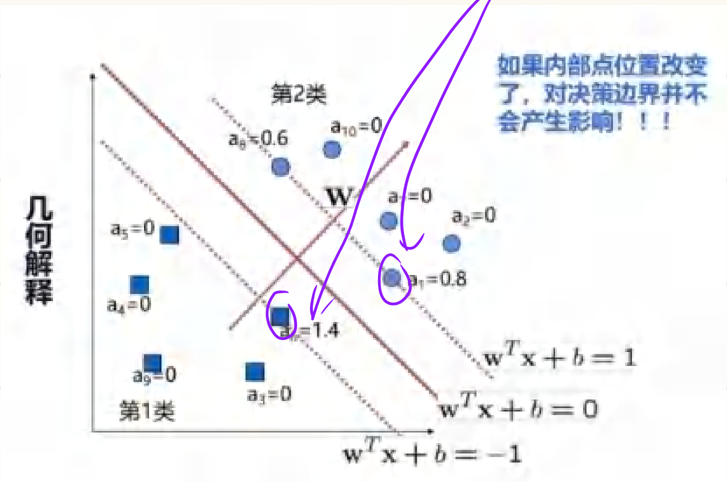
几何解释
第2类
第1类
$a_8=0.6$
$a_{10}=0$
$a_7=0$
$a_2=0$
$a_1=0.8$
$a_5=0$
$a_4=0$
$a_6=1.4$
$a_9=0$
$a_3=0$
W
$w^Tx+b=1$
$w^Tx+b=0$
$w^Tx+b=-1$

如果内部点位置改变了，对决策边界并不会产生影响！！！

第五章 决策树

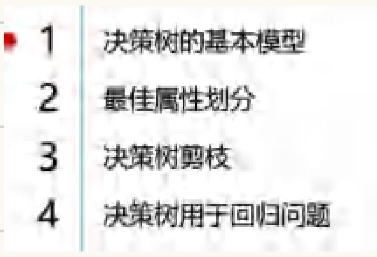

- 1 决策树的基本模型
- 2 最佳属性划分
- 3 决策树剪枝
- 4 决策树用于回归问题

1、决策树模型

根结点、

基于贪心算法：当前状态下分类效果最好的属性

- 建立决策树
- 进行决策树：{ 可多叉，可二叉
  - 可多分类
  - 是非参数 非线性 ☆

2. 最佳属性分

不纯性度量，样本D熵越小，纯度越高

$$Ent(D)=-\sum_{i=1}^{k} p\log_2 p_i$$

① ID3决策树：信息增益，測偏性 $Gain(D,a)=Ent(D)-\sum_{v=1}^{V}\frac{|D^v|}{|D|}Ent(D^v)$ ← 3种特

例：

$Ent(D)$ $D^v_{等1}=324$ $Ent(D^v_{等1})=$

$Ent(D^v_{等2})=$

$Ent(D^v_{等3})=$

特征a：$a^*=\arg\max Gain(D,a)$

$$Gain(D,学生)=Ent(D)-\left(\frac{|D^v_{等1}|}{D}Ent(D^v_{等1})+\frac{|D^v_{等2}|}{D}Ent(D^v_{等2})+\frac{|D^v_{等3}|}{D}Ent(D^v_{等3})\right)$$

② ID4.5决策树：解决（分支多）（过拟合）

决策：$\boxed{增益率}$，算法 IIE

③ CART决策树 二叉树 回归 [illegible]

决策：基尼系数 min $Gini(D)=$ 多分类 $\boxed{1-\sum p_k^2}$ $=$ 二分类 $\boxed{2p(1-p)}$ ↑ 纯↓

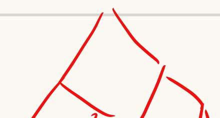

$$Gini\_index(D,a)=\sum_{v=1}^{V}\frac{|D^v|}{|D|}Gini(D^v)$$

对连续属性，找 Gain(D,a)最大的划分点、

缺失：无缺失算 → $Gain(\tilde{D},年龄)$ } ⊗ 相乘 → Gain(D,年龄)
无缺失样本 → 比例

3、决策树剪枝 防过拟合

① 前、后剪枝

② 依正确率剪枝，acc↑则剪

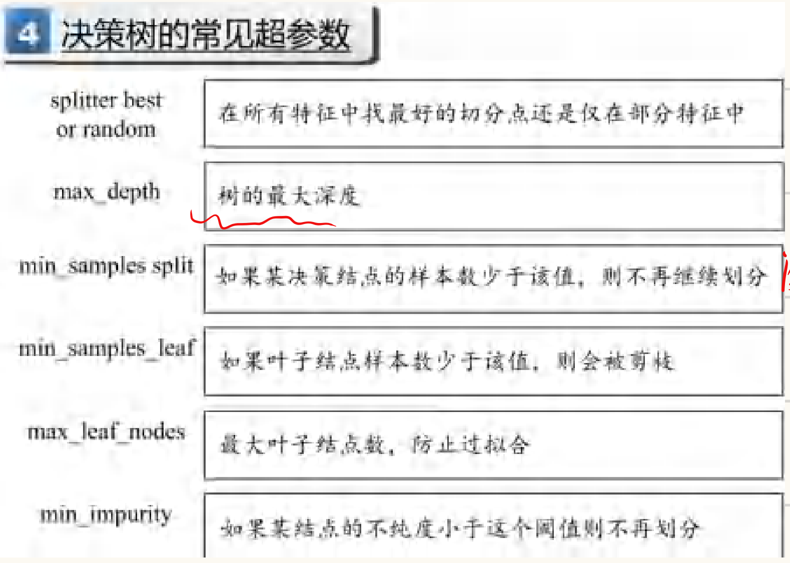

4 决策树的常见超参数

splitter best or random	在所有特征中找最好的切分点还是仅在部分特征中
max_depth	树的最大深度
min_samples split	如果某决策结点的样本数少于该值，则不再继续划分
min_samples_leaf	如果叶子结点样本数少于该值，则会被剪枝
max_leaf_nodes	最大叶子结点数，防止过拟合
min_impurity	如果某结点的不纯度小于这个阈值则不再划分

阈值

4、回归决策树

划分空间，值取均值　　(回归做MSE)

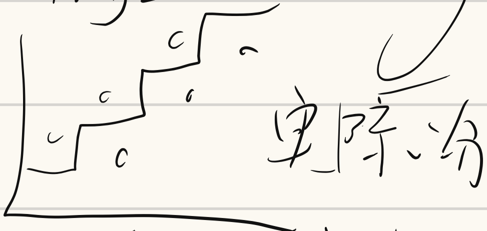

实际、分段函数

① 最小二乘回归树

划分2个区域，最优划分：两个区域平方误差和最小

L(s) 均方误差 min

例子：

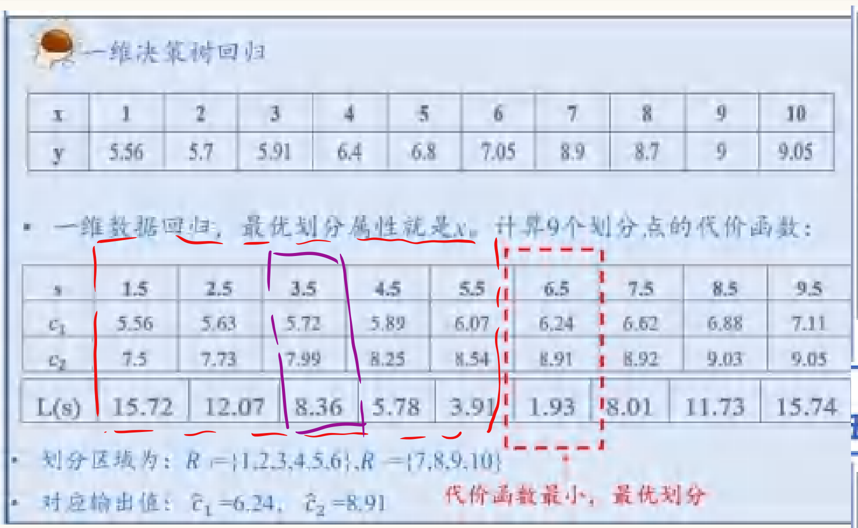

一维决策树回归

x	1	2	3	4	5	6	7	8	9	10
y	5.56	5.7	5.91	6.4	6.8	7.05	8.9	8.7	9	9.05

- 一维数据回归，最优划分属性就是x。计算9个划分点的代价函数：

s	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
c_1	5.56	5.63	5.72	5.89	6.07	6.24	6.62	6.88	7.11
c_2	7.5	7.73	7.99	8.25	8.54	8.91	8.92	9.03	9.05
L(s)	15.72	12.07	8.36	5.78	3.91	1.93	8.01	11.73	15.74

- 划分区域为：$R_1=\{1,2,3,4,5,6\}, R_2=\{7,8,9,10\}$
- 对应输出值：$\hat{c}_1=6.24$，$\hat{c}_2=8.91$

代价函数最小，最优划分

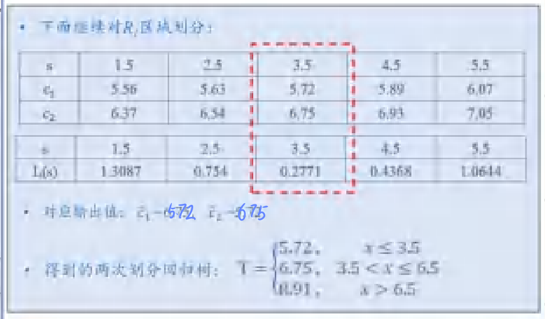

- 下面继续对R_1区域划分：

s	1.5	2.5	3.5	4.5	5.5
c_1	5.56	5.63	5.72	5.89	6.07
c_2	6.37	6.54	6.75	6.93	7.05

s	1.5	2.5	3.5	4.5	5.5
L(s)	1.3087	0.754	0.2771	0.4368	1.0644

- 对应输出值：$\hat{c}_1=5.72$，$\hat{c}_2=6.75$
- 得到的两次划分回归树：$T=\begin{cases}5.72, & x\le 3.5\\ 6.75, & 3.5<x\le 6.5\\ 8.91, & x>6.5\end{cases}$

R₂划分

五讲 决策树

武汉大学 WUHAN UNIVERSITY

e.g.一维决策树回归

x	1	2	3	4	5	6	7	8	9	10
y	5.56	5.7	5.91	6.4	6.8	7.05	8.9	8.7	9	9.05

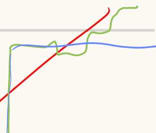

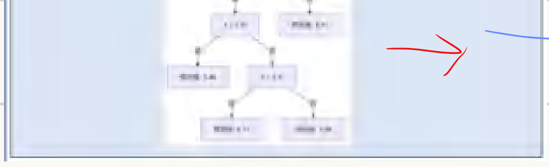

根、决策结点，叶结点.

VC维　↓ 深度 叶数

考试：计算 ID3　CART

第六章　集成学习

好而不同？多、同种类 learner < 决策树 / 神经网络 / 支持向量机

多专家组合（并行）< 全局，Bagging Stacking / 局部

多级组合（串行）Boosting

1、装袋 Bagging 与随机森林

基于自助采样法，

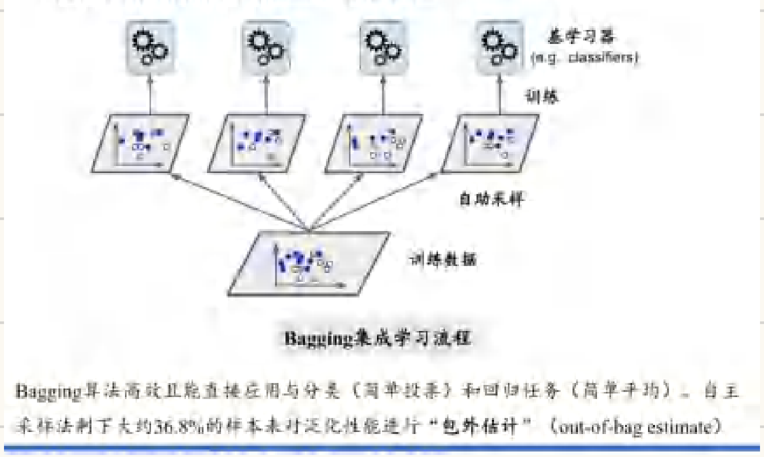

➢ 照此来得到T个采样集，然后基于采样集来训练基学习器，最终使用投票或平均策略将这些学习器组合

基学习器
(e.g. classifiers)
训练
自助采样
训练数据

Bagging集成学习流程

Bagging算法高效且能直接应用与分类（简单投票）和回归任务（简单平均）。自主采样法剩下大约36.8%的样本来对泛化性能进行“包外估计”（out-of-bag estimate）

标签不平衡：随机欠采样：再 Bagging

① 平均法　$\sum_{i=1} w_i = 1$　　$W^T X + W_0$

② 投票法 < 绝对多数 / 相对多数 / 加权投票　　g_t < 类标记 / 类概率

随机森林：

样本采样 / 特征选择 > 随机 — 差异性

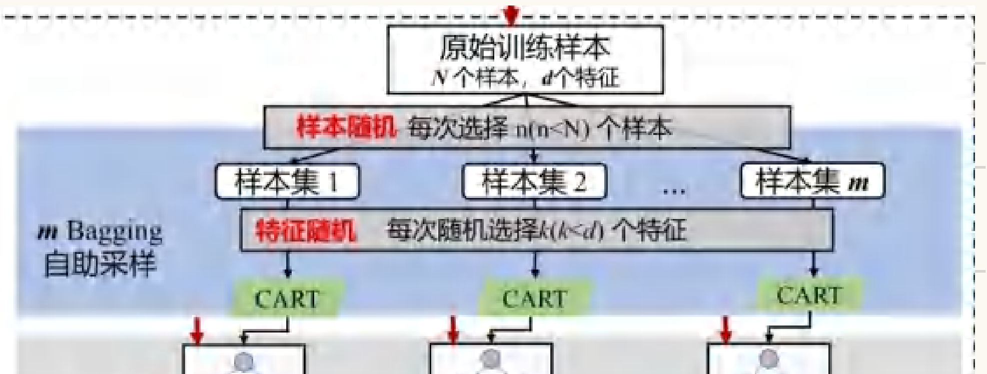

原始训练样本
N 个样本，d个特征
样本随机 每次选择 n(n<N) 个样本
样本集 1
样本集 2
…
样本集 m
m Bagging
自助采样
特征随机 每次随机选择k(k<d) 个特征
CART
CART
CART

➢ 随机森林方法简单、易实现、计算开销小，在很多实际任务中展

样性

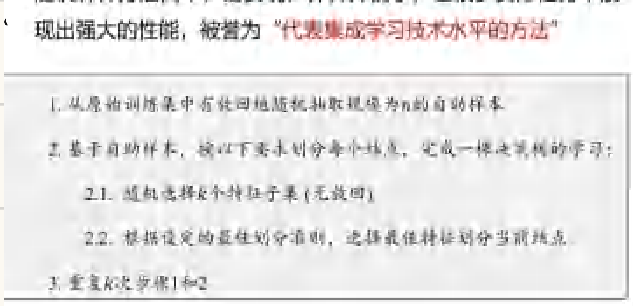

现出强大的性能，被誉为"代表集成学习技术水平的方法"

1. 从原始训练集中有放回地随机抽取规模为n的自助样本
2. 基于自助样本，按以下要求划分每个结点，完成一棵决策树的学习：
    2.1. 随机选择k个特征子集(无放回)
    2.2. 根据设定的最佳划分准则，选择最佳特征划分当前结点
3. 重复K次步骤1和2

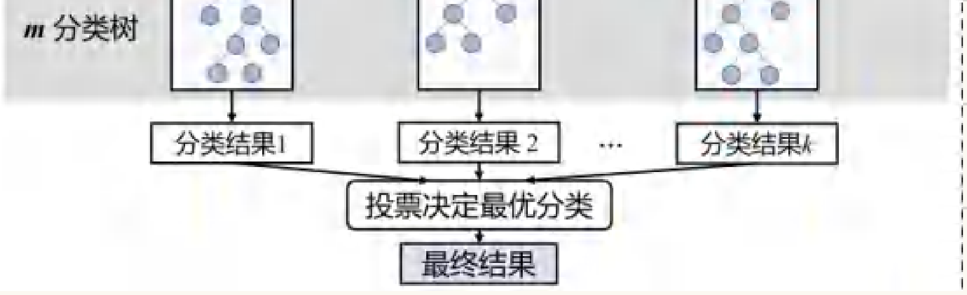

Bagging 降低方差:

2、堆叠(Stacking) 串并

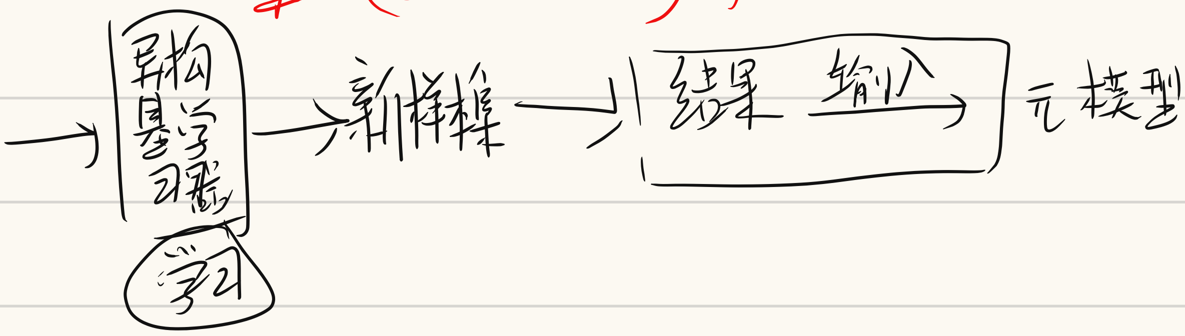

例子： 5折, K交叉

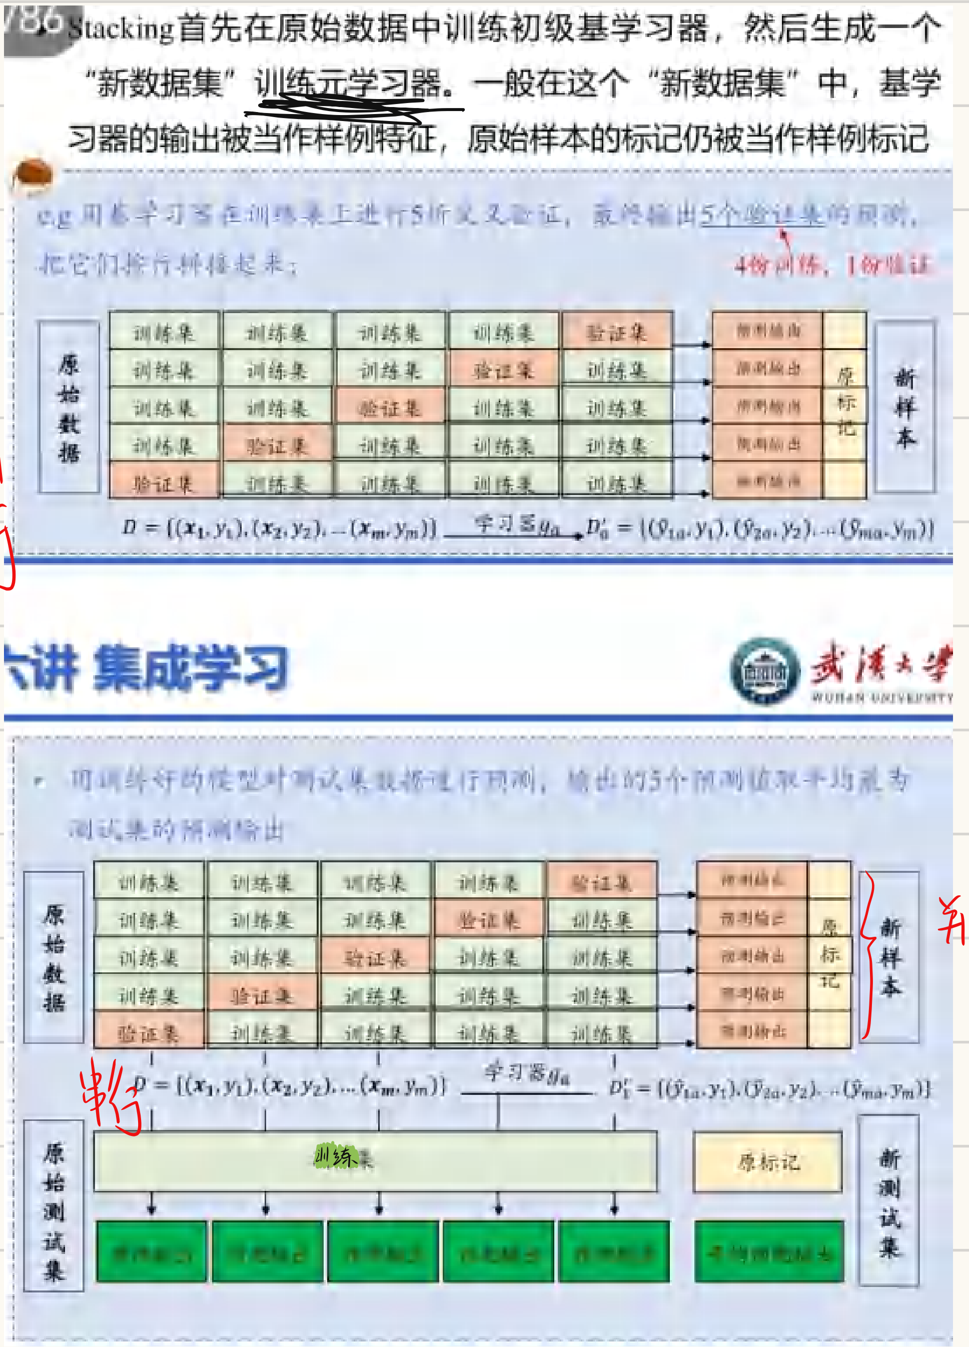

Stacking首先在原始数据中训练初级基学习器，然后生成一个"新数据集"训练元学习器。一般在这个"新数据集"中，基学习器的输出被当作样例特征，原始样本的标记仍被当作样例标记

e.g 用基学习器在训练集上进行5折交叉验证，最终输出5个验证集的预测，把它们按行拼接起来；

4份训练，1份验证

原始数据							新样本
训练集	训练集	训练集	训练集	验证集	预测输出	原标记	
训练集	训练集	训练集	验证集	训练集	预测输出		
训练集	训练集	验证集	训练集	训练集	预测输出		
训练集	验证集	训练集	训练集	训练集	预测输出		
验证集	训练集	训练集	训练集	训练集	预测输出		

$$D=\{(x_1,y_1),(x_2,y_2),\dots(x_m,y_m)\}\xrightarrow{学习器g_a}D'_a=\{(\hat{y}_{1a},y_1),(\hat{y}_{2a},y_2),\dots(\hat{y}_{ma},y_m)\}$$

并行

- 用训练好的模型对测试集数据进行预测，输出的5个预测值取平均值为测试集的预测输出

原始数据							新样本
训练集	训练集	训练集	训练集	验证集	预测输出	原标记	
训练集	训练集	训练集	验证集	训练集	预测输出		
训练集	训练集	验证集	训练集	训练集	预测输出		
训练集	验证集	训练集	训练集	训练集	预测输出		
验证集	训练集	训练集	训练集	训练集	预测输出		

并

$$D=\{(x_1,y_1),(x_2,y_2),\dots(x_m,y_m)\}\quad 学习器g_a\quad D'_1=\{(\hat{y}_{1a},y_1),(\hat{y}_{2a},y_2),\dots(\hat{y}_{ma},y_m)\}$$

串行

原始测试集	训练集					原标记	新测试集
	预测输出	预测输出	预测输出	预测输出	预测输出	平均预测输出	

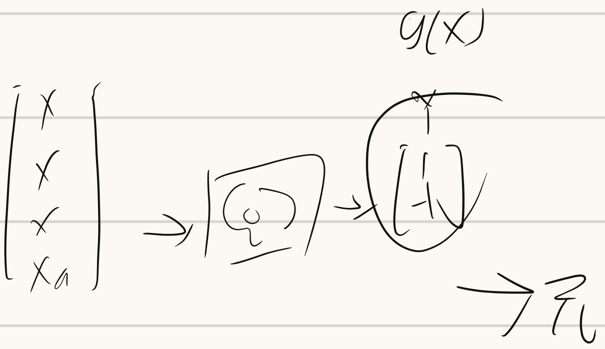

验证集
留来了.

3、提升(Boosting) 提升树 串行

基学习器(弱学习器)

重采样
重赋权

样本有权，会变：boosting

① AdaBoost：自适应

对样本权进行调整，最终分类是基分类器的权线性组合

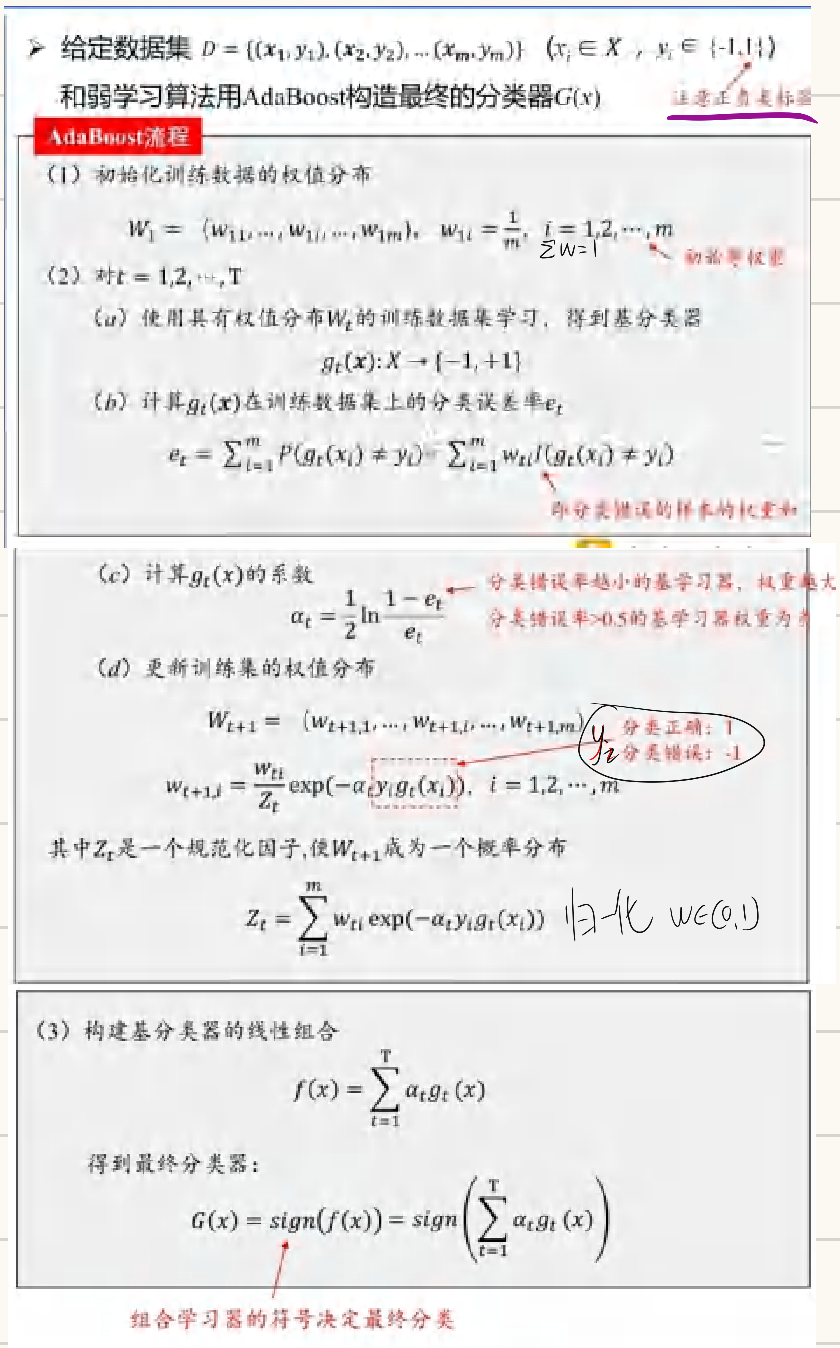

- 给定数据集 $D=\{(x_1,y_1),(x_2,y_2),\ldots(x_m,y_m)\}$ $(x_i\in X,\ y_i\in\{-1,1\})$ 和弱学习算法用AdaBoost构造最终的分类器$G(x)$

注意正负类标签

AdaBoost流程

（1）初始化训练数据的权值分布

$$W_1=(w_{11},\cdots,w_{1i},\cdots,w_{1m}),\quad w_{1i}=\frac{1}{m},\quad i=1,2,\cdots,m$$

$\Sigma W=1$

初始等权重

（2）对$t=1,2,\cdots,T$

（a）使用具有权值分布W_t的训练数据集学习，得到基分类器

$$g_t(x):X\to\{-1,+1\}$$

（b）计算$g_t(x)$在训练数据集上的分类误差率e_t

$$e_t=\sum_{i=1}^{m}P(g_t(x_i)\neq y_i)=\sum_{i=1}^{m}w_{ti}I(g_t(x_i)\neq y_i)$$

即分类错误的样本的权重和

（c）计算$g_t(x)$的系数

$$\alpha_t=\frac{1}{2}\ln\frac{1-e_t}{e_t}$$

分类错误率越小的基学习器，权重越大
分类错误率>0.5的基学习器权重为负

（d）更新训练集的权值分布

$$W_{t+1}=(w_{t+1,1},\cdots,w_{t+1,i},\cdots,w_{t+1,m})$$

$$w_{t+1,i}=\frac{w_{ti}}{Z_t}\exp(-\alpha_t y_i g_t(x_i)),\quad i=1,2,\cdots,m$$

y_i 分类正确：1
分类错误：-1

其中Z_t是一个规范化因子，使W_{t+1}成为一个概率分布

$$Z_t=\sum_{i=1}^{m}w_{ti}\exp(-\alpha_t y_i g_t(x_i))$$

归一化 $w\in(0,1)$

（3）构建基分类器的线性组合

$$f(x)=\sum_{t=1}^{T}\alpha_t g_t(x)$$

得到最终分类器：

$$G(x)=sign(f(x))=sign\left(\sum_{t=1}^{T}\alpha_t g_t(x)\right)$$

组合学习器的符号决定最终分类

权重：根据错误变化　　错了　　更新权重

② 梯度提升树：

以CART为基学习器，用于回归

（类比最小二乘回归树）

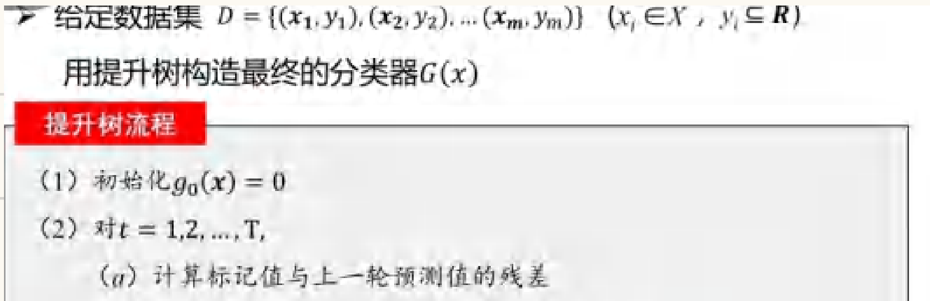

- 给定数据集 $D=\{(x_1,y_1),(x_2,y_2),\ldots(x_m,y_m)\}$ $(x_i\in X,\ y_i\subseteq \mathbf{R})$ 用提升树构造最终的分类器$G(x)$

提升树流程

（1）初始化$g_0(x)=0$

（2）对$t=1,2,\ldots,T,$

（a）计算标记值与上一轮预测值的残差

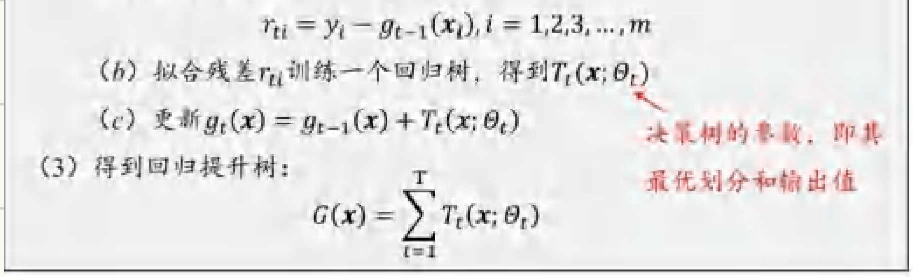

$$r_{ti} = y_i - g_{t-1}(x_i), i = 1,2,3,\dots,m$$

（b）拟合残差r_{ti}训练一个回归树，得到$T_t(x;\theta_t)$

（c）更新$g_t(x) = g_{t-1}(x) + T_t(x;\theta_t)$

决策树的参数，即其最优划分和输出值

（3）得到回归提升树：

$$G(x) = \sum_{t=1}^{T} T_t(x;\theta_t)$$

总体损失：平方误差：$Loss(y_i, g_i(x))^2$

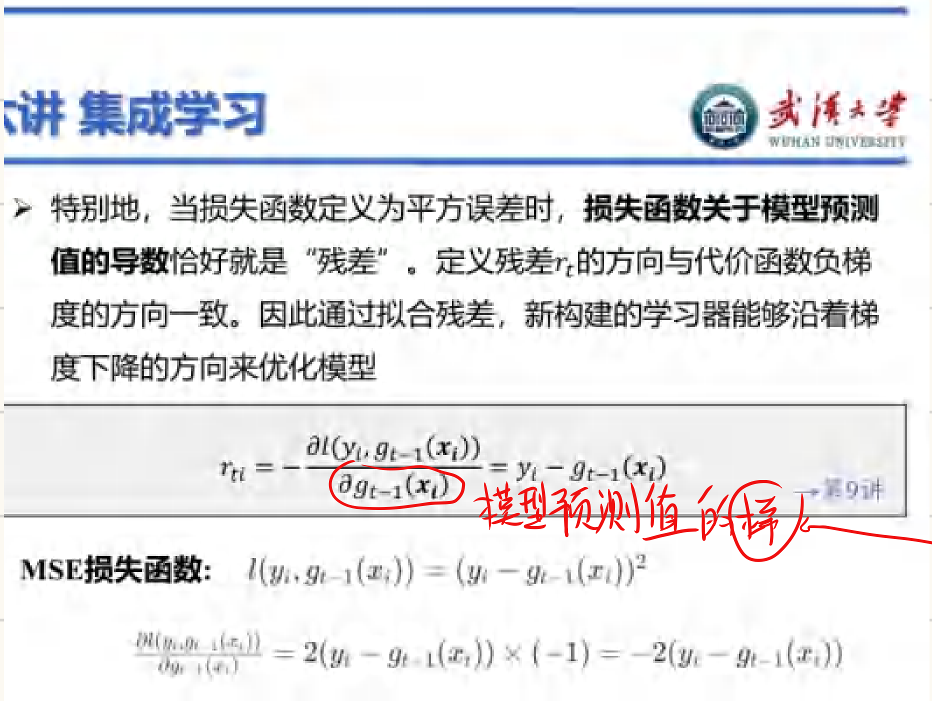

讲 集成学习

武汉大学 WUHAN UNIVERSITY

- 特别地，当损失函数定义为平方误差时，**损失函数关于模型预测值的导数**恰好就是“残差”。定义残差r_t的方向与代价函数负梯度的方向一致。因此通过拟合残差，新构建的学习器能够沿着梯度下降的方向来优化模型

$$r_{ti} = -\frac{\partial l(y_i, g_{t-1}(x_i))}{\partial g_{t-1}(x_i)} = y_i - g_{t-1}(x_i)$$

→第9讲

模型预测值的梯度

MSE损失函数： $l(y_i, g_{t-1}(x_i)) = (y_i - g_{t-1}(x_i))^2$

$$\frac{\partial l(y_i, g_{t-1}(x_i))}{\partial g_{t-1}(x_i)} = 2(y_i - g_{t-1}(x_i)) \times (-1) = -2(y_i - g_{t-1}(x_i))$$

平方损失：$\frac{1}{2}(\hat{y}_i - y_i)^2$

交叉熵损失：

区别：

Bagging 优化方差　Boosting 优化偏差

自助

第七章 维度归约 降维

主成分 PCA

自编码 Autoencoder

多维缩放 MDS

流形学习

降维，新的特征

基向量：⟶新特征空间

线性投影约降维：主成分分析

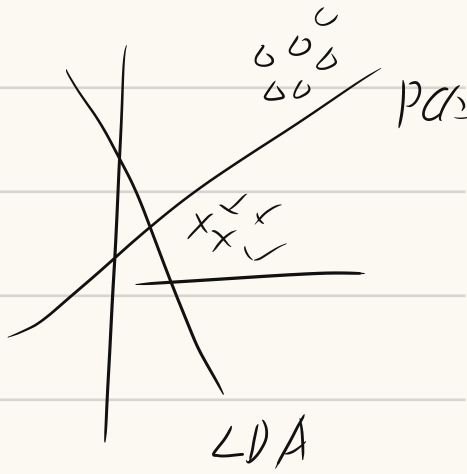

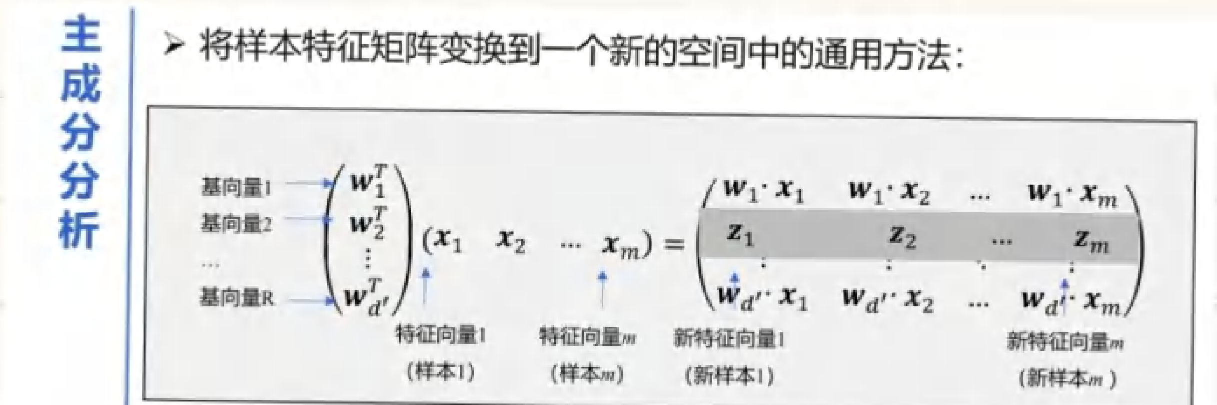

主成分分析

- 将样本特征矩阵变换到一个新的空间中的通用方法：

$$\begin{pmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_{d'}^T \end{pmatrix} (x_1 \quad x_2 \quad \cdots \quad x_m) = \begin{pmatrix} w_1 \cdot x_1 & w_1 \cdot x_2 & \cdots & w_1 \cdot x_m \\ z_1 & z_2 & \cdots & z_m \\ \vdots & \vdots & & \vdots \\ w_{d'} \cdot x_1 & w_{d'} \cdot x_2 & \cdots & w_{d'} \cdot x_m \end{pmatrix}$$

基向量1
基向量2
…
基向量R
特征向量1
（样本1）
特征向量m
（样本m）
新特征向量1
（新样本1）
新特征向量m
（新样本m）

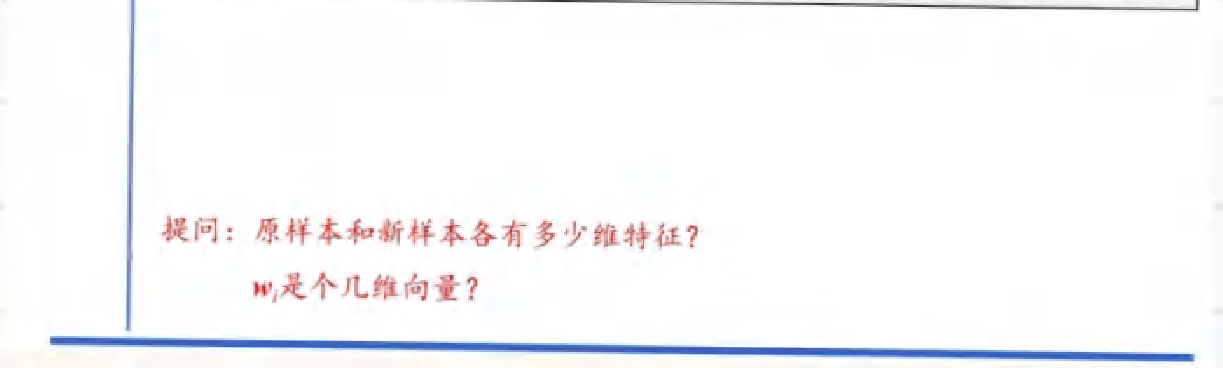

提问：原样本和新样本各有多少维特征？

w_i是个几维向量？

方差最大化、

特征不相关；

由原样本协Σx　$z = W^T x$　$\uparrow$ d'维×d维　选定 w　d'个d维

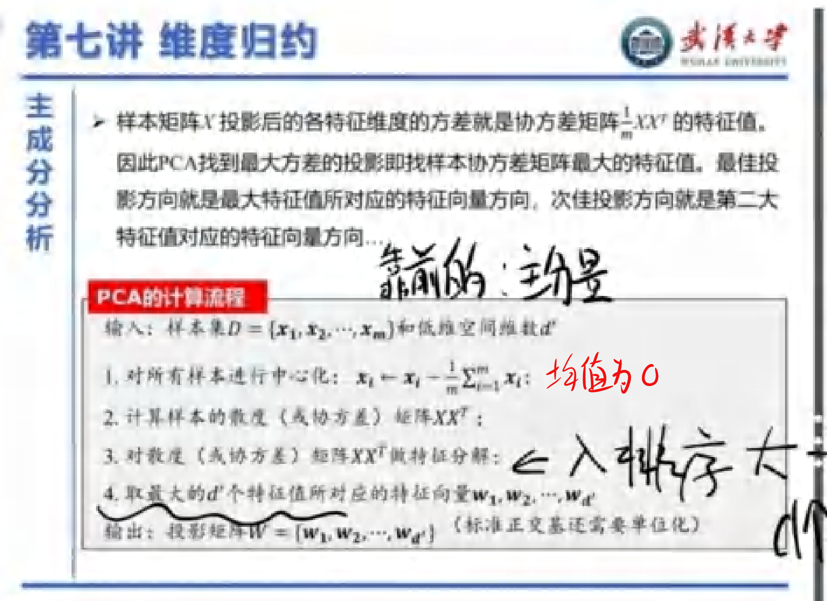

第七讲 维度归约

主成分分析

- 样本矩阵X投影后的各特征维度的方差就是协方差矩阵$\frac{1}{m}XX^T$的特征值。因此PCA找到最大方差的投影即找样本协方差矩阵最大的特征值。最佳投影方向就是最大特征值所对应的特征向量方向，次佳投影方向就是第二大特征值对应的特征向量方向…

靠前的：主分量

PCA的计算流程

输入：样本集$D = \{x_1, x_2, \cdots, x_m\}$和低维空间维数$d'$

1. 对所有样本进行中心化：$x_i \leftarrow x_i - \frac{1}{m}\sum_{i=1}^{m} x_i$； 均值为0
2. 计算样本的散度（或协方差）矩阵XX^T；
3. 对散度（或协方差）矩阵XX^T做特征分解； ← λ排序 大→小
4. 取最大的d'个特征值所对应的特征向量$w_1, w_2, \cdots, w_{d'}$

输出：投影矩阵$W = \{w_1, w_2, \cdots, w_{d'}\}$（标准正交基还需要单位化）

d个取d'个

相关系数均0

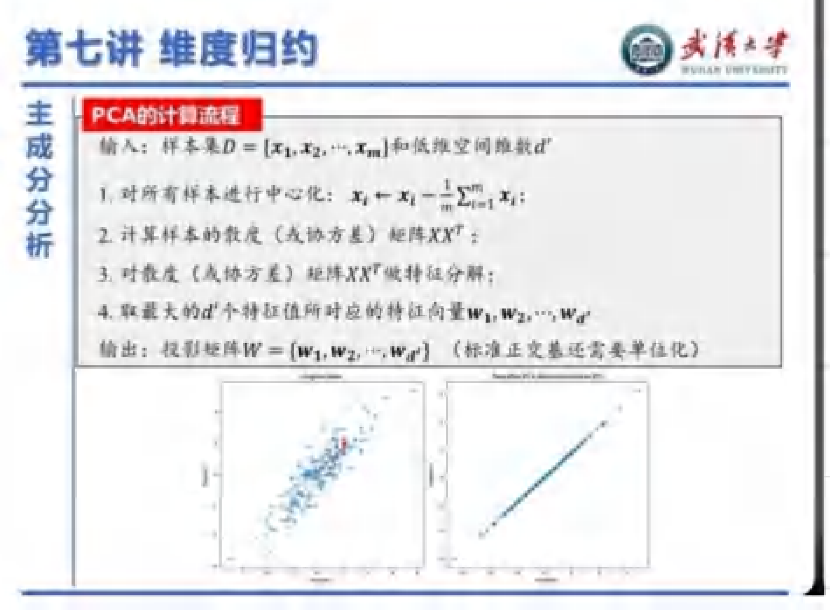

第七讲 维度归约

主成分分析

PCA的计算流程

输入：样本集$D = \{x_1, x_2, \cdots, x_m\}$和低维空间维数$d'$

1. 对所有样本进行中心化：$x_i \leftarrow x_i - \frac{1}{m}\sum_{i=1}^{m} x_i$；
2. 计算样本的散度（或协方差）矩阵XX^T；
3. 对散度（或协方差）矩阵XX^T做特征分解；
4. 取最大的d'个特征值所对应的特征向量$w_1, w_2, \cdots, w_{d'}$

输出：投影矩阵$W = \{w_1, w_2, \cdots, w_{d'}\}$（标准正交基还需要单位化）

PCA流程

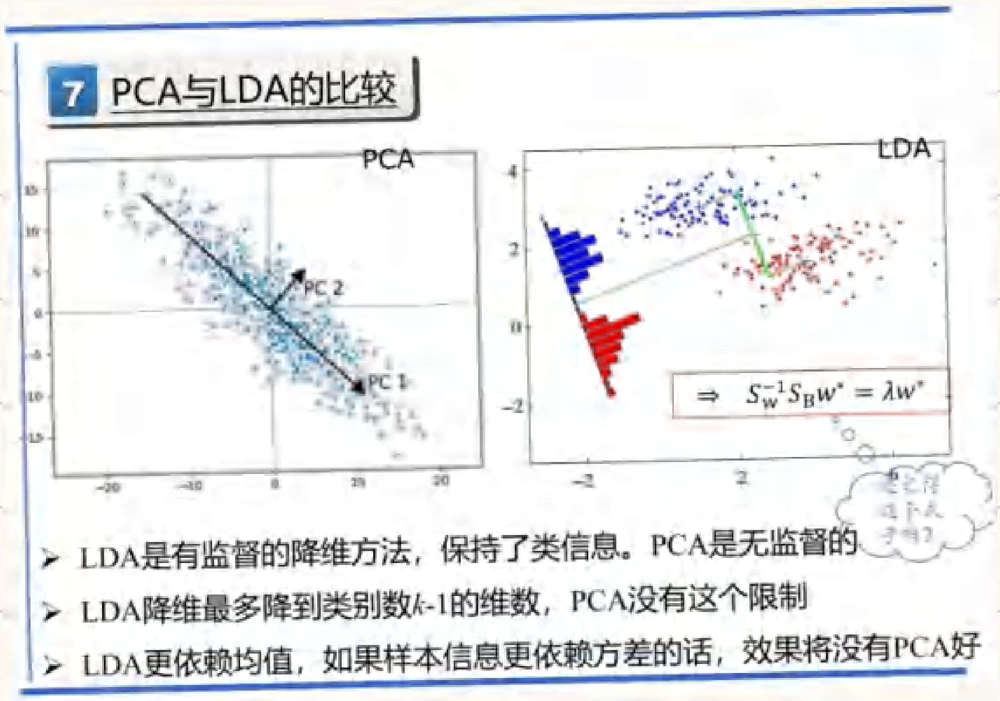

7 PCA与LDA的比较

PCA
PC 2
PC 1
-20
-10
0
10
20
LDA
4
2
0
-2
-2
2

$$\Rightarrow \quad S_W^{-1} S_B w^* = \lambda w^*$$

- LDA是有监督的降维方法，保持了类信息。PCA是无监督的
- LDA降维最多降到类别数k-1的维数，PCA没有这个限制
- LDA更依赖均值，如果样本信息更依赖方差的话，效果将没有PCA好

激活函数 线性　　min

自编码器　$\boxed{x} \Rightarrow \boxed{\ } \Rightarrow \boxed{x}$
编　线　解

MDS 多维标定：低维子空间　样本间距离不变 ☆ core

流形学习：等度量映射 Isomap

第八章 聚类 无监督

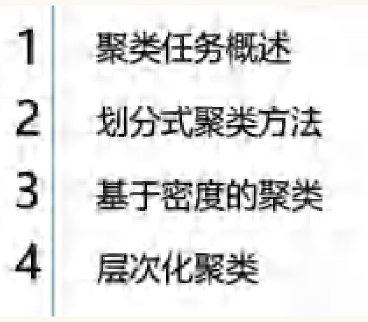
1 聚类任务概述
2 划分式聚类方法
3 基于密度的聚类
4 层次化聚类

距离度量：
- 非负
- 同一
- 对称
- 直递

马氏距离　$D_m(x)=\sqrt{(x_i-\mu)^T\Sigma^{-1}(x_i-\mu)}$ 到分布　当 $\Sigma=I \Rightarrow$ 欧氏距离

优：①不受单位量纲 ②标准化，中心化相同

缺：

性能评估：

外部指标：参考"测试集"
- $a=|SS|$ ：同一簇
- $b=|SD|$ ：聚同点，参不同点、
- $c=|DS|$ ：聚不同，参同
- $d=|DD|$ ：乱序，都不同点。

越大越好
- $JC=\frac{a}{a+b+c}$ (以上)
- FMI: $\sqrt{\frac{a}{a+b}\times\frac{a}{a+c}}$
- RI: $\frac{2(a+d)}{m(m-1)}$

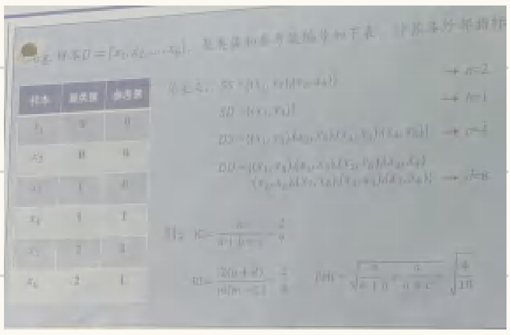

内部指标：$DBI=\frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{avg(C_i)+avg(C_j)}{d_{cen}(\mu_i,\mu_j)}\right)$

"簇内小 "簇间大

① 任两i,j簇，[每个avg / 两类中心距离 $d_{cen}(\mu_i,\mu_j)$] 越小越好

② k，遍历，找max值

③ 取最大均值

2. 划分式聚类方法

先定k个中心，迭代修正

① k-means（k超参数）

对E求min，对所有点判归属

缺点：① k ② 敏感，初始μ，异常

② k-means++：优化初始k个均值的选取

3. 基于密度的聚类算法

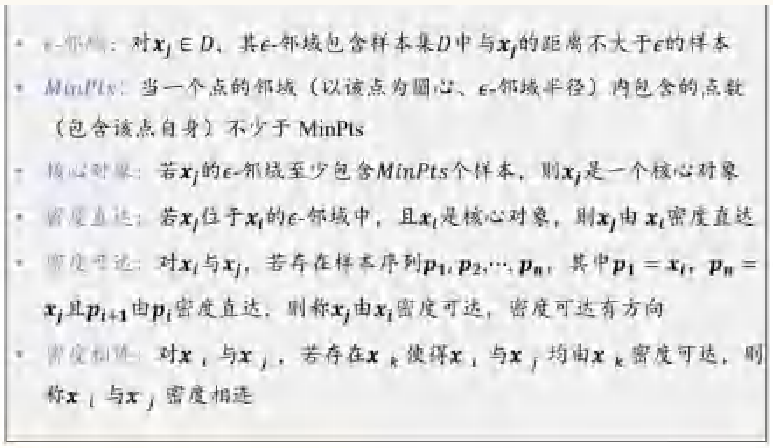

- ε-邻域：对$x_j \in D$，其ε-邻域包含样本集D中与x_j的距离不大于ε的样本
- MinPts：当一个点的邻域（以该点为圆心、ε-邻域半径）内包含的点数（包含该点自身）不少于MinPts
- 核心对象：若x_j的ε-邻域至少包含MinPts个样本，则x_j是一个核心对象
- 密度直达：若x_j位于x_i的ε-邻域中，且x_i是核心对象，则x_j由x_i密度直达
- 密度可达：对x_i与x_j，若存在样本序列$p_1, p_2, \cdots, p_n$，其中$p_1 = x_i$，$p_n = x_j$且p_{i+1}由p_i密度直达，则称x_j由x_i密度可达，密度可达有方向
- 密度相连：对x_i与x_j，若存在x_k使得x_i与x_j均由x_k密度可达，则称x_i与x_j密度相连

参

DBSCAN：

特点：① 确定ε，MinPts
② 不设k
③ 初值、噪声不敏感
④ 对密度不均，不好

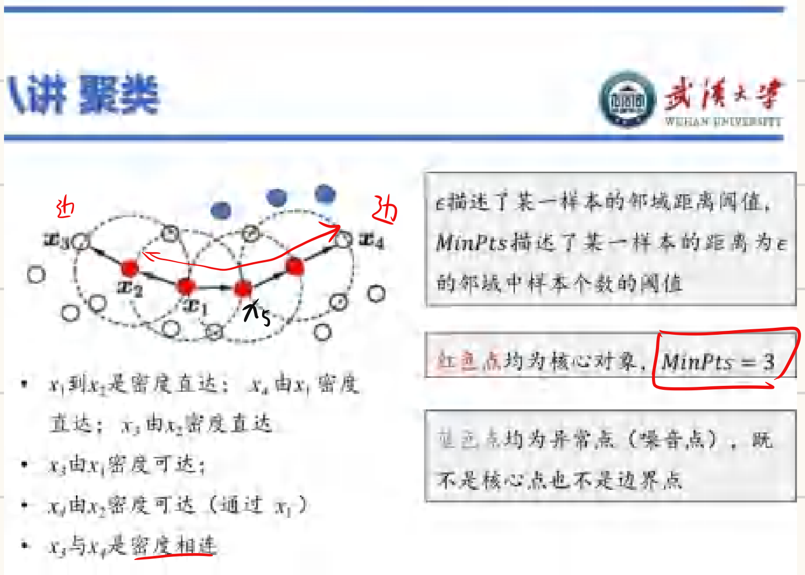

讲 聚类

武漢大學 WUHAN UNIVERSITY

ε描述了某一样本的邻域距离阈值，MinPts描述了某一样本的距离为ε的邻域中样本个数的阈值

红色点均为核心对象，MinPts = 3

蓝色点均为异常点（噪音点），既不是核心点也不是边界点

- x_1到x_2是密度直达；x_4由x_1密度直达；x_3由x_2密度直达
- x_3由x_1密度可达；
- x_4由x_2密度可达（通过x_1）
- x_3与x_4是密度相连

密度可达 $\xrightarrow{簇}$ 样本集合

4. 层次化聚类

同类相近　异类相异

$\boxed{凝聚}$、$\boxed{分裂}$

AGNES　计算2个类簇的相似度

GMM 高斯混合：

2. EM初始化 $\theta = \{\pi_1 \pi_2 \cdots \pi_k, \mu_1 \cdots \mu_k, \Sigma_1 \cdots \Sigma_k\}$

随机初始化：k个μ_k，$\pi_k = \frac{1}{k}$ 和经验
k-means初始：k法

3、参数估计 EM算法

第九章 last 大 神经网络

1 概念
2、多层前馈 sjwl
3、BP 神经wl

§ 概念

生物神经 <
- 广泛连接
- 非线性
- 并行分布
- adp

①

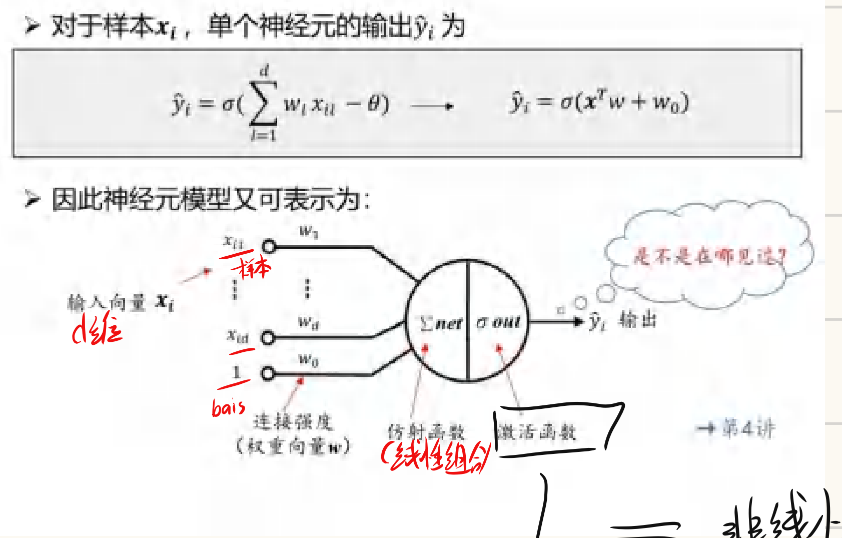

➢ 对于样本x_i，单个神经元的输出$\hat{y}_i$为

$$\hat{y}_i=\sigma\left(\sum_{l=1}^{d} w_l x_{il}-\theta\right) \longrightarrow \hat{y}_i=\sigma(x^T w+w_0)$$

➢ 因此神经元模型又可表示为：

x_{i1}
样本
输入向量 x_i
d维
x_{id}
1
bais
w_1
w_d
w_0
连接强度（权重向量w）
Σnet
σ out
仿射函数
(线性组合)
激活函数
$\hat{y}_i$ 输出
是不是在哪见过？
→第4讲

—— 非线性 ——

Sigmoid $\frac{1}{1+e^{-x}}$ $f'(x)=f(x)(1-f(x))$

Tanh $\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$ 求导 ⟹ $f'(x)=1-(f(x))^2$

} 饱和激函

ReLU $f'(x)=\begin{cases}0 & x\le 0\\ 1 & x>0\end{cases}$

②神经网络

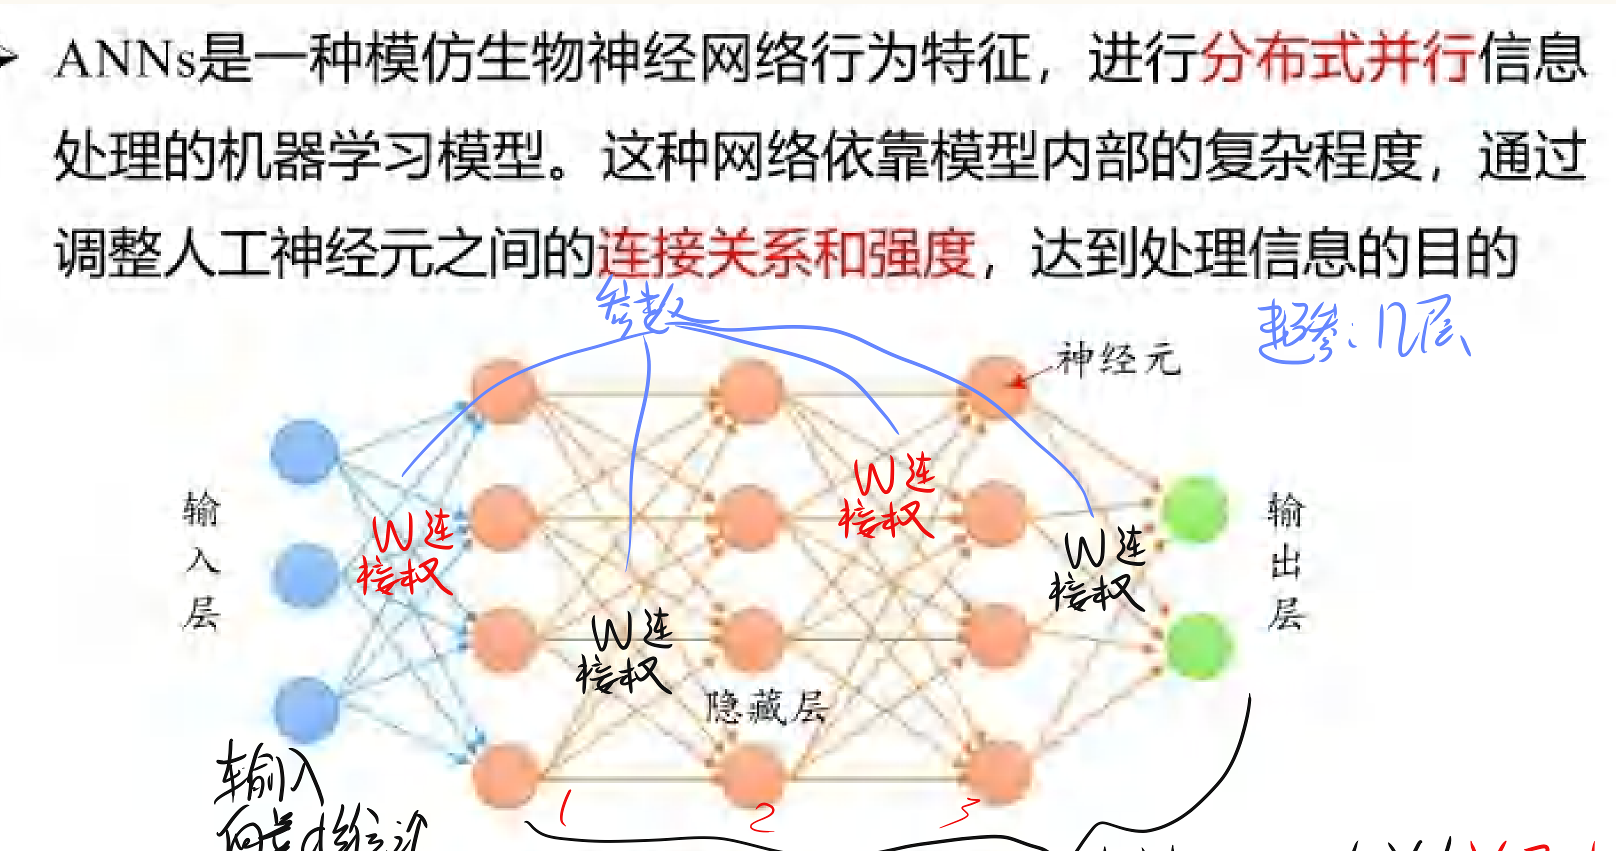

➢ ANNs是一种模仿生物神经网络行为特征，进行分布式并行信息处理的机器学习模型。这种网络依靠模型内部的复杂程度，通过调整人工神经元之间的连接关系和强度，达到处理信息的目的

参数
超参：几层
神经元
输入层
隐藏层
输出层
W连接权
W连接权
W连接权
W连接权
1
2
3
输入
向量d维

人工神经网络的典型结构

有神经元：有激活函数

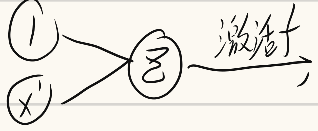

多层前馈 SJWL

BP 神经网络

➢ ANNs是一种模仿生物神经网络行为特征，进行**分布式并行**信息 工作

处

调

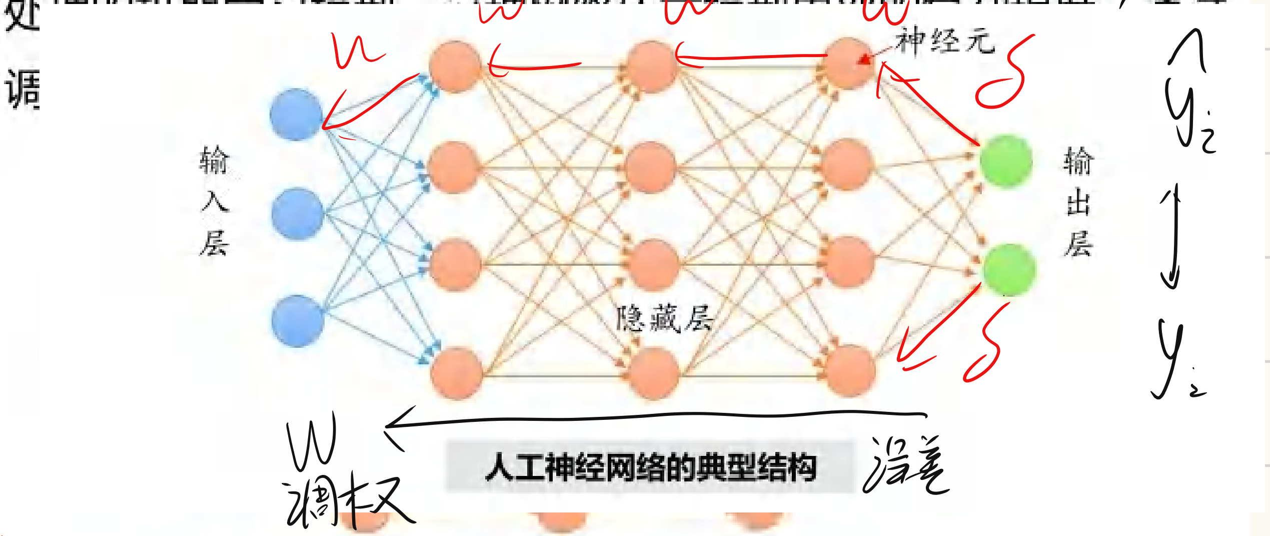
w
w
w
w
神经元
δ
δ
输入层
隐藏层
输出层
$\hat{y}_i$
y_i
W 调权
误差

人工神经网络的典型结构

人工神经网络的典型结构

有监督

① 学习规则：感知机规则

$$w^{(t+1)} = w^{(t)} + \eta(\underset{\text{真}}{y_i} - \underset{\text{模型估值}}{\hat{y}_i})x_i$$

监督 ↓ 真

模型估值

神经元 x_i

η：缩定：学习率、步长、梯度下降

中引入了**δ规则**，也称为连续感知机学习规则，以**目标（损失函数）的负梯度方向对参数进行调整**

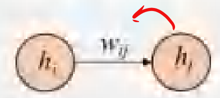

$$w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta \cdot \frac{\partial Loss}{\partial w_{ij}^{(t)}} = w_{ij}^{(t)} - \eta \cdot \boxed{\delta_{h_j}} \cdot \boxed{out_{h_i}}$$

损失的梯度在 w_{ij} 方向的分量

$\frac{\partial loss}{\partial net_{h_j}} \cdot \frac{\partial net}{\partial w} \rightarrow \frac{\partial w \cdot out}{\partial w} = out$

神经元h_j的误差信号

神经元h_i的输出

② BP算法 更新权W的算法

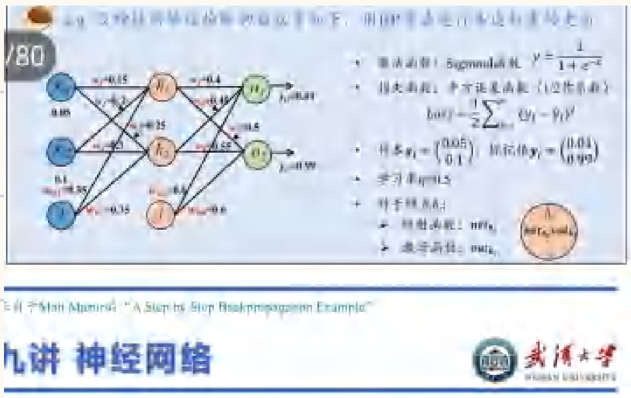
/80

$y = \frac{1}{1+e^{-x}}$

"A Step by Step Backpropagation Example"

九讲 神经网络

武汉大学

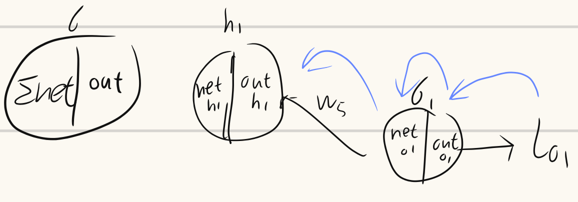
i
Σnet
out
h_1
net h_1
out h_1
w_5
o_1
net o_1
out o_1
L_{o_1}

$$w_1 = w_1 - \eta \cdot \frac{\partial loss}{w_1}$$

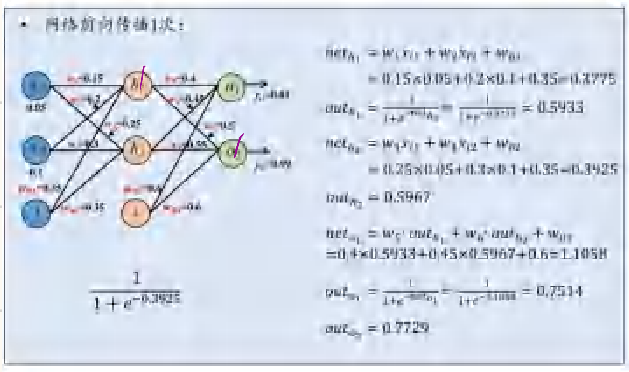

- 网络前向传播1次：

$net_{h_1} = w_1x_{i1} + w_3x_{i2} + w_{01}$
$= 0.15\times0.05+0.2\times0.1+0.35=0.3775$

$out_{h_1} = \frac{1}{1+e^{-net_{h_1}}} = \frac{1}{1+e^{-0.3775}} = 0.5933$

$net_{h_2} = w_2x_{i1} + w_4x_{i2} + w_{02}$
$= 0.25\times0.05+0.3\times0.1+0.35=0.3925$

$out_{h_2} = 0.5967$

$net_{o_1} = w_5 \cdot out_{h_1} + w_6 \cdot out_{h_2} + w_{03}$
$=0.4\times0.5933+0.45\times0.5967+0.6=1.1058$

$out_{o_1} = \frac{1}{1+e^{-net_{o_1}}} = \frac{1}{1+e^{-1.1058}} = 0.7514$

$out_{o_2} = 0.7729$

$\frac{1}{1+e^{-0.3925}}$

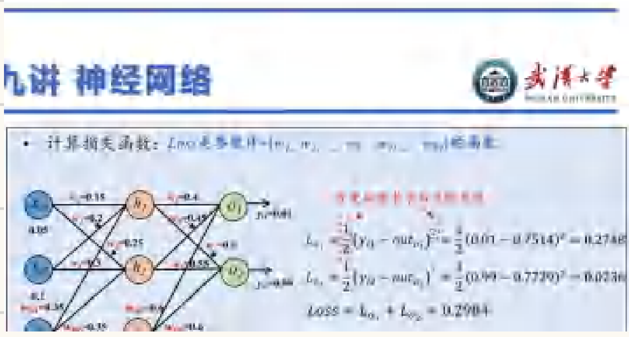

九讲 神经网络　　武汉大学

- 计算损失函数：Loss是参数W=($w_1, w_2, \ldots, w_{01}, \ldots w_{04}$)的函数

$L_{o_1} = \frac{1}{2}(y_{i1} - out_{o_1})^2 = \frac{1}{2}(0.01-0.7514)^2 = 0.2748$

$L_{o_2} = \frac{1}{2}(y_{i2} - out_{o_2})^2 = \frac{1}{2}(0.99-0.7729)^2 = 0.0236$

$Loss = L_{o_1} + L_{o_2} = 0.2984$

$net_{o_1} \mid out_{o_1} \to L_{o_1}$ 算

$w_5 \leftarrow w_5 - \eta \cdot \frac{\partial loss}{\partial w_5}$

实则： $\frac{\partial loss}{\partial w_1} = [w_5 \times \delta_{o1} + w_7 \times \delta_{o2}] \times \frac{\partial out_{h1}}{\partial net_{h1}} \times x_{i1} = \delta_{h1} \times x_{i1}$

$W_{hi} \leftarrow W_{hi} - \eta \cdot \underbrace{\frac{\partial loss}{\partial W_{hi}}}_{\eta \cdot \delta_{h_1} \cdot x_{ij}}$

$x_{i1} \xrightarrow{w_i} h_i$

对于 $\delta_{h_j}^{(i)}$ ： $\left(\sum_{i=1}^{n} \delta_{h_i}(i+1) \cdot W_{jl}\right) \cdot \frac{\partial out_{h_j}}{\partial net_{h_j}}$

偏L → 修正

梯度下降更新参数w

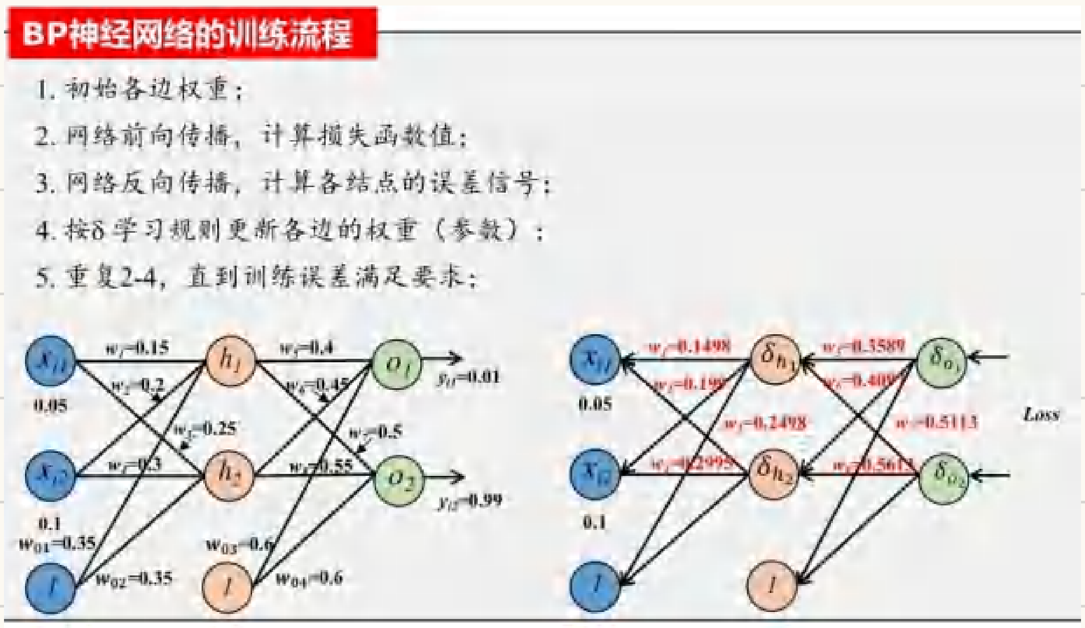

BP神经网络的训练流程

1. 初始各边权重；
2. 网络前向传播，计算损失函数值；
3. 网络反向传播，计算各结点的误差信号；
4. 按δ学习规则更新各边的权重（参数）；
5. 重复2-4，直到训练误差满足要求；

x_{i1}
x_{i2}
0.05
0.1
h_1
h_2
o_1
o_2
w_1=0.15
w_2=0.2
w_3=0.25
w_4=0.3
w_5=0.4
w_6=0.45
w_7=0.5
w_8=0.55
w_{01}=0.35
w_{02}=0.35
w_{03}=0.6
w_{04}=0.6
y_{i1}=0.01
y_{i2}=0.99
1
δ_{h_1}
δ_{h_2}
δ_{o_1}
δ_{o_2}
w_1=0.1498
w_2=0.199
w_3=0.2498
w_4=0.2995
w_5=0.3589
w_6=0.4087
w_7=0.5113
w_8=0.5613
Loss

批量梯↓ ： 全部遍历　Loss计算全样本 → 更新　MSE

随机梯↓ ： Loss计算随机挑一条，局部最优　振荡

小批梯↓ ： Batch Size　折中

$w = w - \eta \frac{\partial loss}{\partial w}$

输出层： δ 损失函数导数 及 输出神经元激活函数导数

回归：
- 平方误　loss： $\frac{1}{2}(\hat{y}_i - y_i)^2$　　$|\hat{y} - y_i|$
- 均方　loss： $\frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2$　　$\frac{1}{m}\sum_{i=1}^{m}|\hat{y}_i - y_i|$

二分类交叉熵： loss ： $-[y_i \ln\hat{y}_i + (1-y_i)\ln(1-\hat{y}_i)]$　　$\left[\frac{-y_i}{\hat{y}_i} + \frac{1-y_i}{1-\hat{y}_i}\right]$

δ_o

多分类 softmax：$Loss = -\sum_{j=1}^{k} y_{ij} \ln \hat{c}_j$ 真 估

交叉熵

$\delta_0 = \frac{\partial loss}{\partial \hat{y}_2} \times \frac{\partial \hat{y}_2}{\partial net_0} = \left[\frac{-y_2}{\hat{y}_2} + \frac{1-y_2}{1-\hat{y}_2}\right]$ 激活函数$''/_{out_j}$

估－真

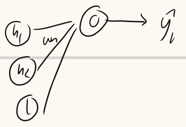

交叉熵损失+ Sigmoid 激活

死记硬背：$\delta_{0j} = \hat{c}_j - y_{ij}$ 反映了估值偏离程度

特别注意. ①各神经元激活函数导数 $\begin{cases} >1 & 梯爆 \\ <1 & 梯消 \end{cases}$

- Sigmoid 饱和
- Tanh
- Relu 函数特点

②自适应动态学习率：积累动量 代替梯度，更新 → 指数加权平均

动量：前一时刻 v 与当前 g

$g = \frac{\partial Loss}{\partial w_i^{(t)}}$

RMSprop

Adam

$v^+ \leftarrow \gamma v + \eta g$

更新 $w^+ \leftarrow w - v^+$

$v^+ \leftarrow \gamma v + (1-\gamma) g^2$

$w^+ = w - \eta \frac{g}{\sqrt{v} + \delta}$

Adam

$s \leftarrow$

$r \leftarrow$

$w^+ = w - \frac{\eta s}{\sqrt{r} + \delta}$

③防过拟合：
- 早停：训练集,验证集,返回最小验证集误差 w,
- 正则化：L1 L2 停止神经元 Dropout
- 标签平滑：独热(hotting)加噪声，防拟合
- 批量归一化：加速收敛：均值方差归一化，γ, β 参数

模型结构

net

cnt

w bais

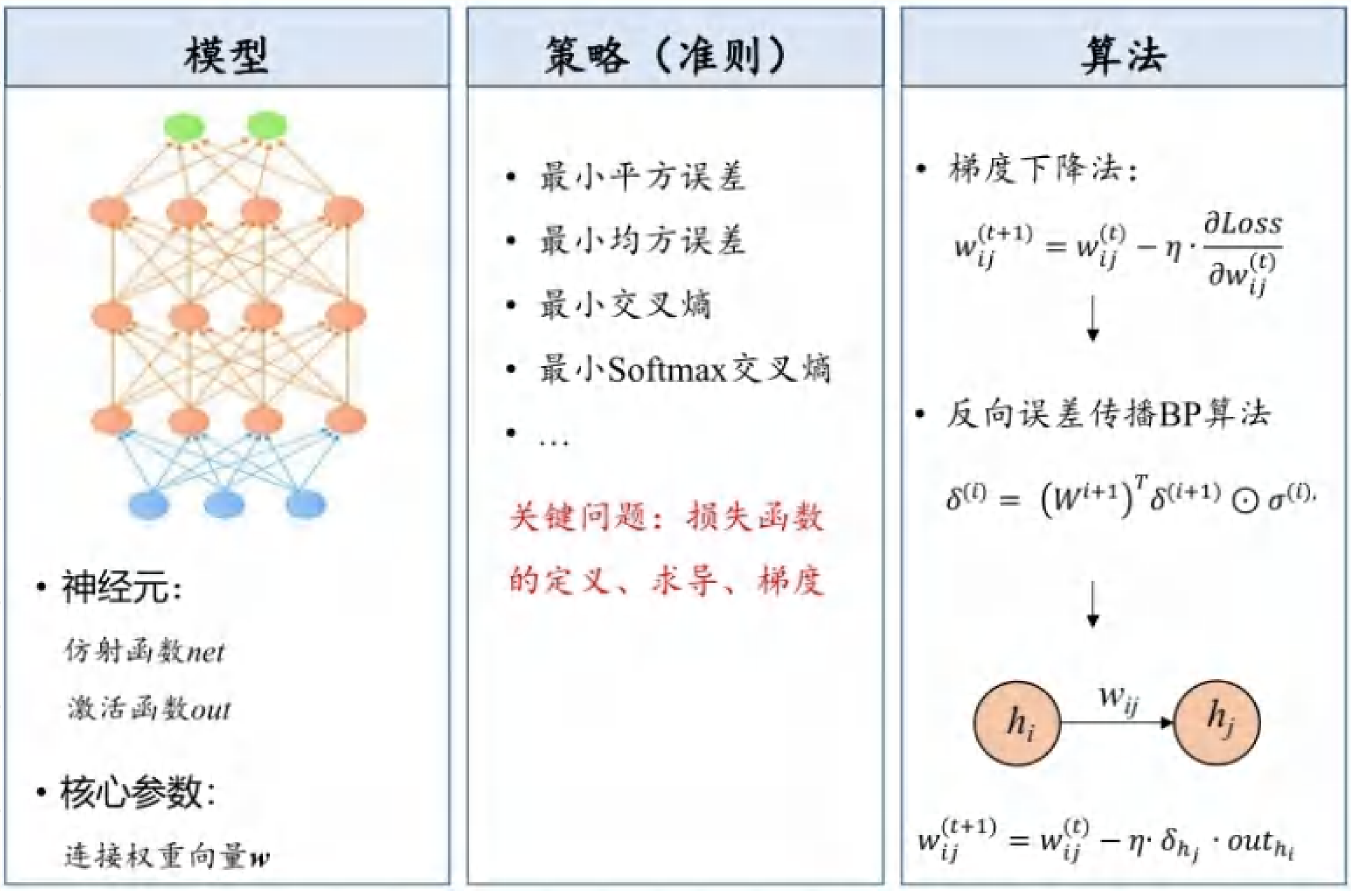

模型	策略（准则）	算法
• 神经元： 仿射函数 *net* 激活函数 *out* • 核心参数： 连接权重向量 *w*	• 最小平方误差 • 最小均方误差 • 最小交叉熵 • 最小Softmax交叉熵 • … 关键问题：损失函数的定义、求导、梯度	• 梯度下降法： $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta \cdot \frac{\partial Loss}{\partial w_{ij}^{(t)}}$ ↓ • 反向误差传播BP算法 $\delta^{(l)} = (W^{l+1})^T \delta^{(l+1)} \odot \sigma^{(l)}$ ↓ $h_i \xrightarrow{w_{ij}} h_j$ $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta \cdot \delta_{h_j} \cdot out_{h_i}$

第十章：深度学习

卷积：空域滤波，零填充防边缘，

卷积神经网络CNN √ 有监

☆核心 机制

① 局部感受野：

② 池化（下采样）＜ 最大值下采 / 平均下采

CNN 基本结构

A卷积层、b池化层

① 卷积层：提取特征

② 池化层：降数据维度 下采样，

③ 全连接层：

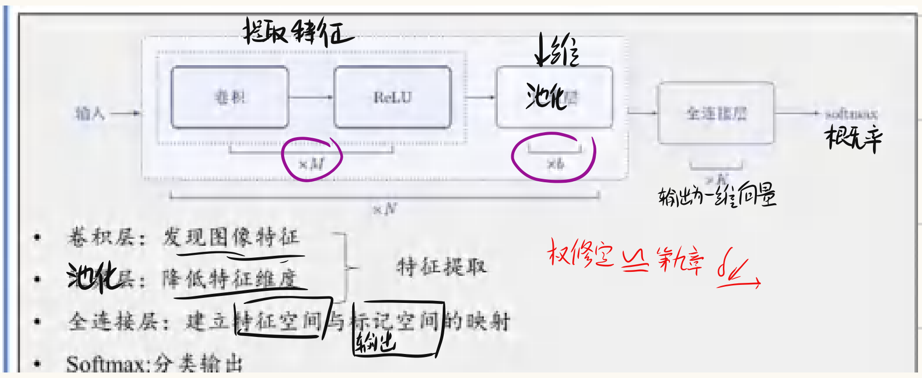

提取特征
输入
卷积
ReLU
↓维
池化层
全连接层
softmax
概率
×M
×b
×K
×N
输出为一维向量

- 卷积层：发现图像特征
- 池化层：降低特征维度
- 全连接层：建立特征空间与标记空间的映射 输出
- Softmax:分类输出

特征提取

权修正 见 第九章 δ

问题： 5x5x10 + 10个 bais

(5x5x1+1) x10

大小 32x32 28 14 10 5 1

参数 (5x5x3+1)6 (1+1)6 (5x5(6+1))16 (1+1)16 → 卷 (5x5(16+1))120

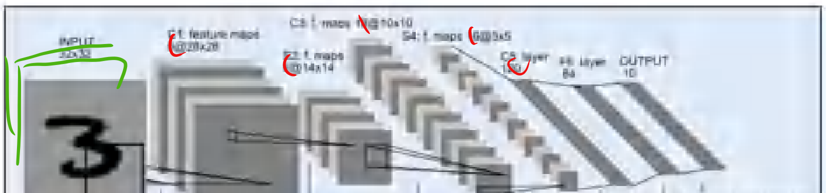

INPUT 32x32
C1: feature maps 6@28x28
S2: f. maps 6@14x14
C3: f. maps 16@10x10
S4: f. maps 16@5x5
C5: layer 120
F6: layer 84
OUTPUT 10
3

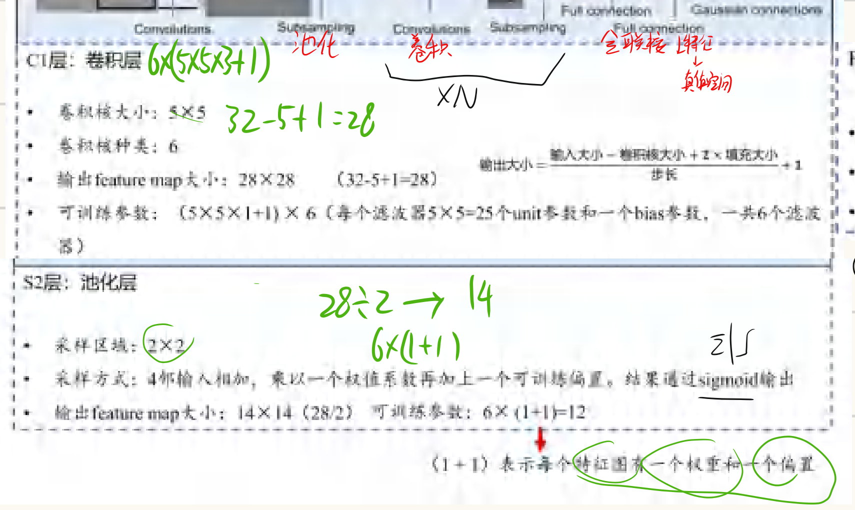
Convolutions
Subsampling
Convolutions
Subsampling
Full connection
Full connection
Gaussian connections
池化
卷积
×N
全联接
特征
真值空间

C1层：卷积层 6×(5×5×3+1)

- 卷积核大小：5×5 32-5+1=28
- 卷积核种类：6
- 输出feature map大小：28×28 （32-5+1=28）
- 可训练参数：（5×5×1+1）×6（每个滤波器5×5=25个unit参数和一个bias参数，一共6个滤波器）

$$输出大小 = \frac{输入大小 - 卷积核大小 + 2 \times 填充大小}{步长} + 1$$

S2层：池化层

28÷2 → 14
6×(1+1)
Σ|∫

- 采样区域：2×2
- 采样方式：4邻输入相加，乘以一个权值系数再加上一个可训练偏置，结果通过sigmoid输出
- 输出feature map大小：14×14（28/2） 可训练参数：6×（1+1）=12

（1+1）表示每个特征图有一个权重和一个偏置

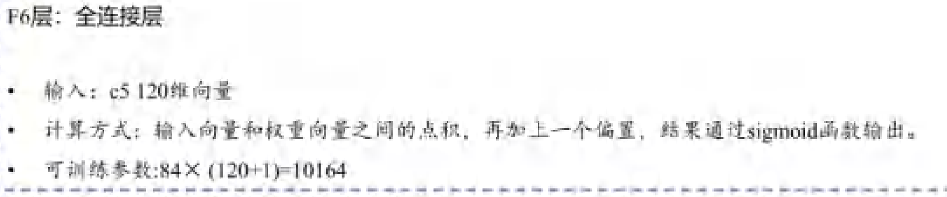

F6层：全连接层

- 输入：c5 120维向量
- 计算方式：输入向量和权重向量之间的点积，再加上一个偏置，结果通过sigmoid函数输出。
- 可训练参数:84×（120+1）=10164

Output 也是全连接层

第十一讲 CV

第十二讲 注意机制 Transformer

词向量与词嵌入
注意力机制
Transformer

词向量：相似性
向量运算

词嵌入：词语映射→向量空间.
Word2Vec

注意力 注意力权

软
① 计算向量相似度：打分 $s(x_i,q)$ （缩放因子d，① 高维点积结果大，指数运算溢出
② softmax不均匀、梯度爆炸、
② softmax算注意力分布：α_i
③ $att=\sum\alpha_i x_i$ 注意力输出 与原本
键值对注意力：键k 值v 查q 索引

硬

自注意力：QKV同输入

多头注意力：

①位置编码

②编码层
- 多头注意
- 残差连接：梯爆消 传达
- 加层归一：速度泛化 $\gamma\frac{x-\mu}{\sqrt{\sigma^2+\epsilon}}+\beta$
- 前馈神经
  - 两层