压题卷

(24-25分) 一、选择题 概率;平台上的 理解应用。 11-12章分别一道选择题

Yolo < 目标网络 / 变 / 主 ★用途 检测图像 对齐

注意力 自注意力 建立 Wk Wv 维度相同 变为可学习的

概念 相同点 多头注意力 目的: 维度降了 优势!

(40分)二、问答(4x10) 章节知识点串讲串起来;
有小计算 理解名用, 优缺 策略选择 (看关键字 和XX)
有文字描述 背

逻辑 — 语言组织 问答题 关键思想 + 理解

模型 { 名称、目标函数、用途 { 优 缺

Adaboost 步骤 ROC曲线

(36分)三、综合计算(2x18)
1. BP网络 死
2. 树 ID.Gini

鸡鸡

概念 无需解释
样本空间: 向量 $x_i = \begin{pmatrix} x_{i1} \\ x_{id} \end{pmatrix}$ 个数m 维数d
标记空间: { 内部的 内部的
分类 回归
二分 多分 { hotting R / 独热(000,100) (0,0,1)
数据集合 { 训: 训练 经验误差 调参 / 验: 调超参, 找超参 k, 体现泛化 / 测: 评估 性能 泛化误差

一、确定任务目标 分类、回归、聚类 树、线性模型、BP
二、选择模型策略: 选学习准则 = 选目标函数 最小化
{ 经验风险最小 { 对单个样本 Loss函数 { L1 |y-ŷ| / L2 (y-ŷ)² / 交叉熵 −Σy ln ŷ softmax $\frac{e^{y}}{\sum e}$; 整个集: 代价函数: $MSE = \frac{1}{m}\sum(\hat{y}-y)^2$
结构风险最小: 经验 + 复杂度正则化 ↓ 对新样本 泛化误差
三、找优化算法 Loss函数 目标函数(含正则) + 正则

模型容量 表示能力 = 复杂度 VC = k−1 (能被H打散的最大样本数) $H \to \Pi_H(m) = 2^m$ 不可散列 3 4 7

泛化误差 Error = 方差 + 偏差 + 噪声 { 欠 / 过 } 模型 正则化 早停 集成 / 样本 清洗 噪声 交叉验证 / 训练 早停

{ 留出法 (训练集/测试) 分层
超 K折交叉验证 (调超参, 更泛化) 用于估计性能,而非选择参数的算法,是选超参、
一种验证集算法 训 测试 K-1 1
参考: ① 每折 → 指标 ② 选最佳假设 超参 ③ 全部数据重训练 ④ 评估, 独立测试集
自助采样法 训: D' 测: D−D' 包外估计 优: 数据集小, 难划分 缺: 改变了样本分布, 偏差
验证 → 训练集 ↓Ein 测试集 评估

算

真实\预测	正	反
正	TP	FN
反	FP	TN

正确 $\frac{T}{P+N}$ 错误 $\frac{F}{P+N}$ $P_{精度} = \frac{T}{P}$ $R_{召回} = \frac{TP}{TP+FN}$

P-R曲线 大优 关注正类,不放过
★ROC曲线★ TPR FPR AUC = 1 AUC越大越好 PPT例 = 真正例 / 假正例

贝叶斯 分类器

对类条件概率(参数估计) { 贝叶斯: x属于ck类的概率: 后验概率 $P(c|x) = \frac{P(x|c)P(c)}{P(x)}$ 核心:找类条件概率 先验 训练 证据:全概率 $\sum P(x|c_i)P(c_i)$
最小错误 样本→分布 $P(e) = P_2(e)P(c_2) + P_1(e)P(c_1)$ 贝二决策 二分类 总体概率
最小风险 $R(\alpha_i|x) = \sum \lambda_{ij} P(c_j|x)$ 后验 条件风险 风险
★ 朴素贝叶斯: 独立假设: $P(c|x) = \frac{P(c)}{P(x)} \times P(x_1|c) \times P(x_2|c) \times \ldots$
极大似然: $\frac{\partial L(\theta|x)}{\partial \theta}$
隐变量 E-M Q函数 { ★ E步作用: 构Q函数 → 描述完全数据对数似然期望, 选择 θ⁽ᵗ⁾ 的参数 $Q(\theta,\theta^{(t)}) = \sum_{i}\sum_{j} P(z|x_i,\theta^{(t)}) \ln P(x_i, z|\theta)$
M步作用: 最大化Q函数, 求θ̂, $|\theta^{t+1}-\theta^{t}| \le \varepsilon$
★ 特别注意: 对初值选择敏感 ① 影响收敛速度,是否最优, EM必收敛 ② 不同局部最优解
$Q(\theta,\theta^{(t)}) =$ 明确X与隐变量Z 构 $P(x,z|\theta)$ 对数似然 lnP 算在当前θ的后验 $P(z|x,\theta)$ 求期望得Q

线性回归 { 模型 $y = x_i^T w + w_0 = Xw$
目标函数 MSE作代价 $L(w) = \frac{1}{2m}\sum(\hat{y}_i - y_i)^2$
优化算法 $L(w) = (y - Xw)^T(y - Xw)$ 求导为零 { X^TX 可逆 最小二乘 / X^TX 不可逆 梯度下降法 $w = w - \eta\frac{\partial L(w)}{\partial w}$
正则化 { L2 岭: 使所有参数都较小 / L1 套索: 稀疏 $L(w) = \frac{1}{2m}\left[\sum_{i=1}^{m}(\hat{y}_i - y_i)^2 + \lambda\sum_{j=1}^{d} w_j^2 / \lambda\sum_{j=1}^{d}|w_j|\right]$ → 导 $w_k - \eta\left[\frac{1}{2m} \ldots 2\lambda w_k + \frac{\lambda}{j}\right]$
性能: 均方误差 $MSE = \frac{1}{m}\sum(\hat{y}_i - y_i)^2$ R^2 接近1 拟合程度高 $= 1 - \frac{SSE}{SST} = 1 - \frac{(\hat{y}-y)^2}{(y-\bar{y})^2}$

第四章 线性回归

对数几率回归分类 LR 二分 步骤: x_i 线性回归 $z_i = x_i^T w + w_0$ Logistic 映射 $\hat{y}_i = \frac{1}{1+e^{-z}}$ 得概率 P(后验概率)
学习准则: 二分类交叉熵 $-\sum y_i \ln \hat{y}_i$ 非MSE, 非凸
$L(w) = -\sum[y_i(x_i^T w + w_0) - \ln(1 + e^{x^T w + w_0})] + L_2$ 正则化

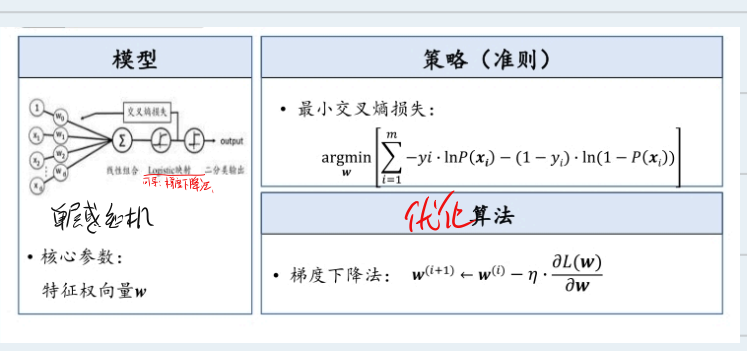

模型	策略（准则）
核心参数: 特征权向量w	• 最小交叉熵损失: $\arg\min_w \sum -y_i \ln P(x_i) - (1-y_i)\ln(1-P(x_i))$
	优化算法 • 梯度下降法: $w^{(t+1)} \leftarrow w^{(t)} - \eta \frac{\partial L(w)}{\partial w}$

多分类 { 一对一, 一对其余 / Softmax 线性回归 权W → $\frac{e^{x_i^T w_j}}{\sum e^{x_i^T w}}$ softmax映射 $P(c_j|x_i)$ 多类输出 独热 学习准则: k分类交叉熵 $-\sum y \ln(\hat{y})$

LDA 线性判别 学习目标 $\arg\max \frac{w^T S_b w}{w^T S_w w}$ 类间散度最大 类内散度最小 ★ 步骤: ① 计算类内/类间 散度矩阵 S_w/S_b ③ 矩阵 $S_w^{-1}S_b$ 最大 k−1 个特征值/特征向量 ④ 将原始样本投影 得到降维后的数据集 D 特性: 有监督 k−1

支持 SVM 决策边界 → 最大化间隔 → 找支持 决定 ★ 什么是支持向量, 到边界, 两类平面,

第五章 树

核心算法 ① 选特征 最佳 ② 划分子集 ③ 递归, 递归建子树 ④ 不能进行, 生成叶节点
ID3 信息增益 MAX $Gain(D,a) = Ent(D) - \frac{D^v}{D} Ent(D^v)$ ① 离散, 非连续 ② 偏多值
ID4.5 增益率 IV = 熵
CART 基尼指数 MIN $Gini\_index(D,a) = \sum \frac{|D^v|}{|D|}(1 - \sum p_k^2)$ ① 连续 ② 剪枝 ③ 二叉, 回归
缺: 乘 不能

第六章 集成学习:

好而不同 多样性 线性

并行 同质 异质 Bagging 方差 多个基学习器 Lenet
自助采样 样本 特征 CART — Ans 平均/投票 随机森林 决策树 样本 特征
Stacking ① 原始数据k折 验证集 生成新 样本标签 ② 输入 元学习器 ③ 测试集
串行 基学习器 Boosting 偏差 基学习器(弱学习器) 重采样 重赋权 初始化学习器 分布调整 步骤 ① 初始化数据权(训练集) ② 将带权数据训练, 得到弱学习器 ③ 计算误差率 e_t, 弱学习器权 $\alpha_t = \frac{1}{2}\ln\frac{1-e_t}{e_t}$, 更新训练集权 ④ 分类器 线性组合 迭代 ⑤ 得最终分类器 $f(x) = \sum \alpha_t h_t(x)$ 正 $We^{-\alpha_t}$ 负 We^{α_t}

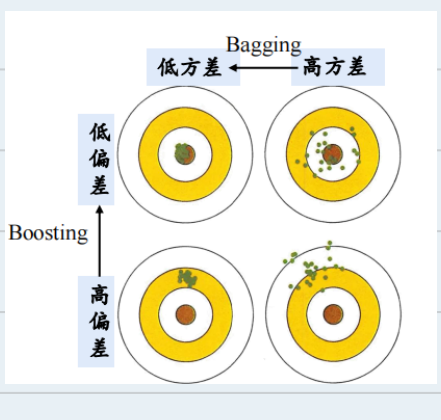

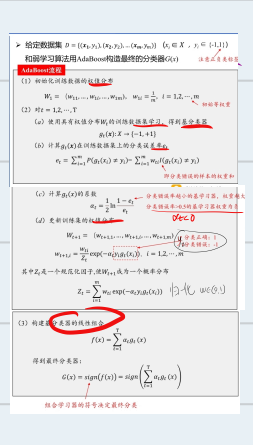

应用: CART决策树 Boosting 梯度提升树 分类/回归

七章 维度归约

降维 ★低维嵌入 无监督
PCA 目标 { 最大可分: 各样本 投影后方差 / 最近重构性: 各样本到超平面距离
定义: 高维的, 相关, 正交变换: 好处 低维, 线性不相关, 主成分

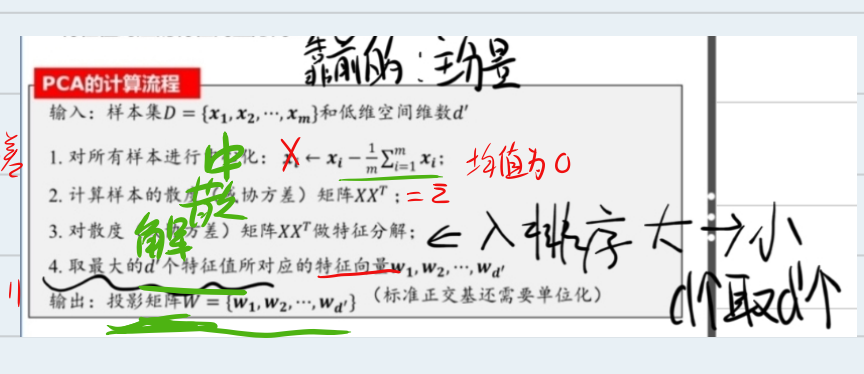

PCA的计算流程 输入: 样本集 D = {x₁, x₂, …, x_m} 和低维空间维数d' 1. 对所有样本进行中心化 2. 计算样本的协方差矩阵 XX^T 3. 对协方差矩阵 XX^T 做特征值分解 4. 取最大的d'个特征值所对应的特征向量 输出: 投影矩阵 W = (w₁, w₂, …, w_d') 均值为0 从大到小 取d'个

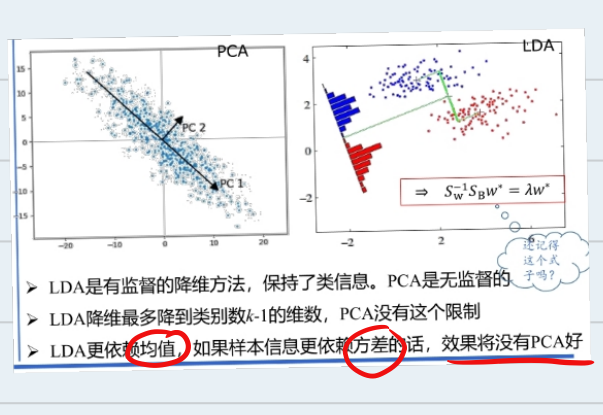

- LDA是有监督的降维方法, 保持了类信息。PCA是无监督的
- LDA降维最多降到类别数k-1的维数, PCA没有这个限制
- LDA更依赖均值, 如果样本信息更依赖方差的话, 效果将没有PCA好

(3,2)在 $(\frac{1}{\sqrt2}, \frac{1}{\sqrt2})$ 上投影 W^TX 坐标 $x = \begin{pmatrix} \frac{1}{\sqrt2} \\ \frac{1}{\sqrt2}\end{pmatrix} + y\begin{pmatrix} -\frac{1}{\sqrt2} \\ \frac{1}{\sqrt2}\end{pmatrix}$ (1,0)(0,1) (3,2)/投 $w = (1,3)^T$ → 单位化 $W^T x$

MDS 多维缩放 低维 样本距离不变

八 聚类

内: DB↓ 外: Jaccard↑ FM↑ ∈(0,1)
原型 K-means 找中心 距离 目标函数 $E = \sum\sum \|x - \mu\|^2$ 最小 K++ 选取初始质心 优化了 ① 随机, 剪枝 ② 第, 均值, 新质心 选到不变
受影响因素 k值确认 初值选取 对异常数据敏感

DBSCAN 组成: 邻域 ε, MinPts 概念: ① 密度 步骤: ① 找核心 ② 找可达 构造簇
优 ① 确定 ε, MinPts ② 不设k ③ 初值 噪 不敏感 缺 ④ 对密度不均, 不好
选择题

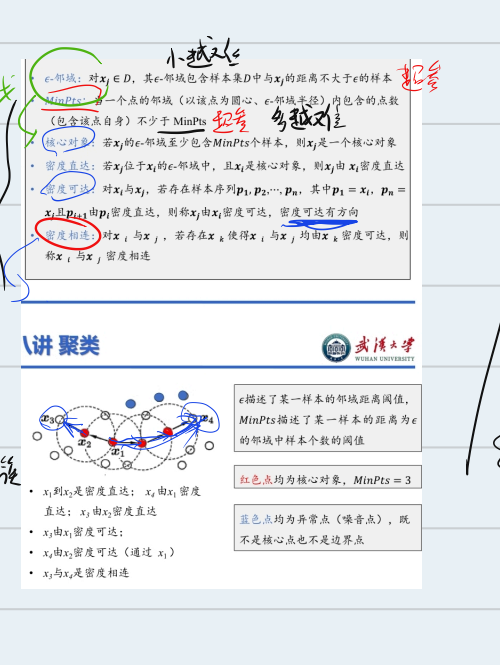

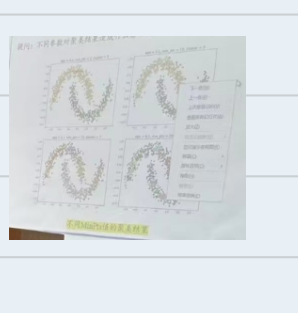

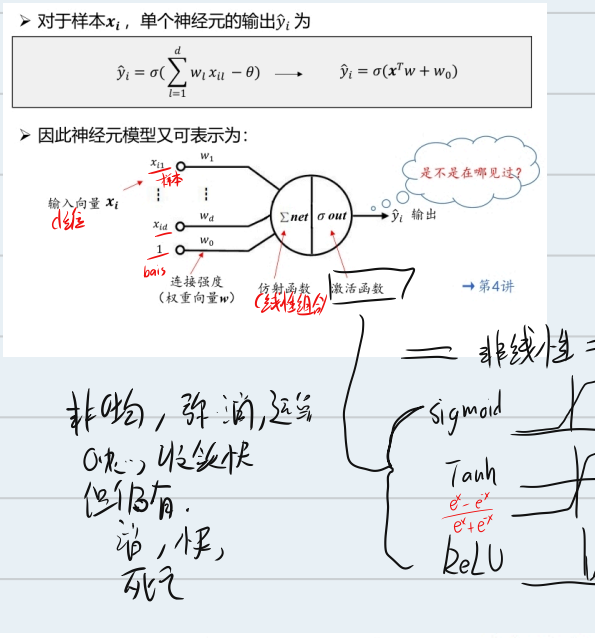

- 对于样本 x_i, 单个神经元的输出 $\hat{y}_i$ 为 $\hat{y}_i = \sigma(\sum_{i=1}^{d} w_i x_{ji} - \theta) \longrightarrow \hat{y}_i = \sigma(x^T w + w_0)$
- 因此神经元模型又可表示为:

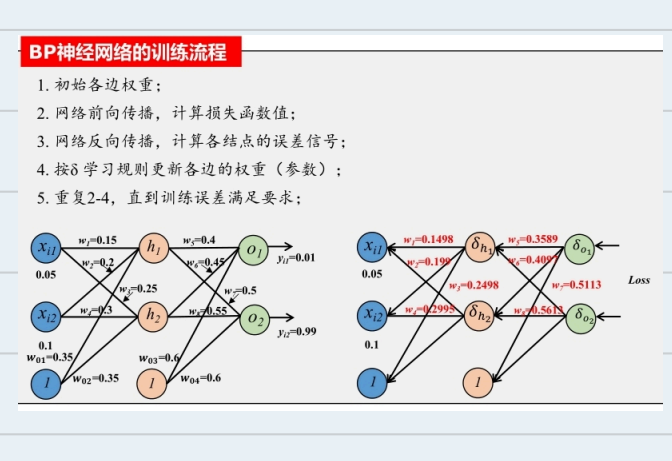

BP神经网络的训练流程
1. 初始各边权重;
2. 网络前向传播, 计算损失函数值;
3. 网络反向传播, 计算各结点的误差信号;
4. 按δ学习规则更新各边的权重(参数);
5. 重复2-4, 直到训练误差满足要求;

非线性 Sigmoid $\frac{1}{1+e^{-x}}$ $f'(x) = f(x)(1-f(x))$ Tanh $\frac{e^x - e^{-x}}{e^x + e^{-x}}$ 求导 $f'(x) = 1 - (f(x))^2$ 饱和激活 两端 → 0 ReLU $f'(x) = \begin{cases} 0 & x \le 0 \\ 1 & x > 0 \end{cases}$ 非饱和, 梯度消失 仅正 死亡

MBGD { 批量梯度: 全部样本 Loss计算全样本 → 更新 MSE / 随机梯度: Loss计算随机一条, 易局部最优 方差大 / 小批梯度: Batch Size 折中 $w = w - \eta\frac{\partial Loss}{\partial w}$

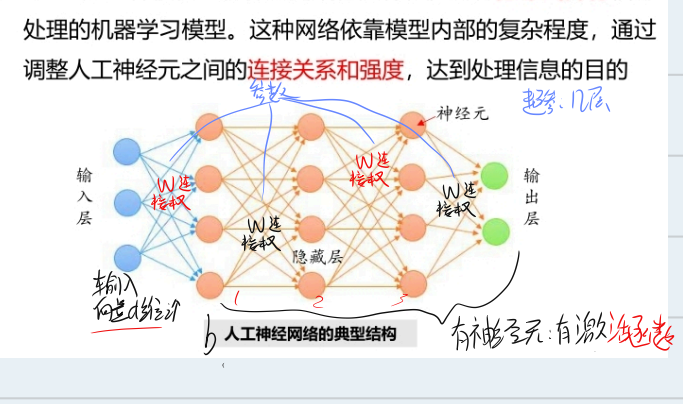

- ANNs是一种模仿生物神经网络行为为特征, 进行分布式并行信息处理的机器学习模型。这种网络依靠模型内部的复杂程度, 通过调整人工神经元之间的连接关系和强度, 达到处理信息的目的

人工神经网络的典型结构

算法:

确定以下问题

输出层 { 损失函数导数 及 输出神经元激活函数导数 回归: 平方误差 $loss = \frac{1}{2}(y-\hat{y})^2$ $(\hat{y}-y)$ 预测 $\delta = (\hat{y}-y)\hat{y}(1-\hat{y})$ 均方 $loss = \frac{1}{2m}\sum(\hat{y}-y)^2$ 二分类交叉熵: $Loss = -[y\ln\hat{y} + (1-y)\ln(1-\hat{y})]$ 多分类 softmax: $Loss = -\sum y_i \ln \hat{y}_i$ 巧记: $\delta_{oj} = \hat{y}_j - y_j$ 估 − 真

特别注意 ① 各神经元激活函数导数 { >1 梯度爆炸 <1 梯度消失 Sigmoid Tanh 饱和 Relu 函数特性!
② 自适应动量学习率: 积累动量 代替梯度, 更新 → 指数加权平均 动量 Adam RMSprop Adan
③ 防过拟合: 早停: 训练集误差, 返回最小验证误差w, 正则化: L1 L2 停止神经元 标签平滑: 增加噪声, 防止 批量归一化, 加速收敛: 均值方差归一化

模型结构 net cnt w bais

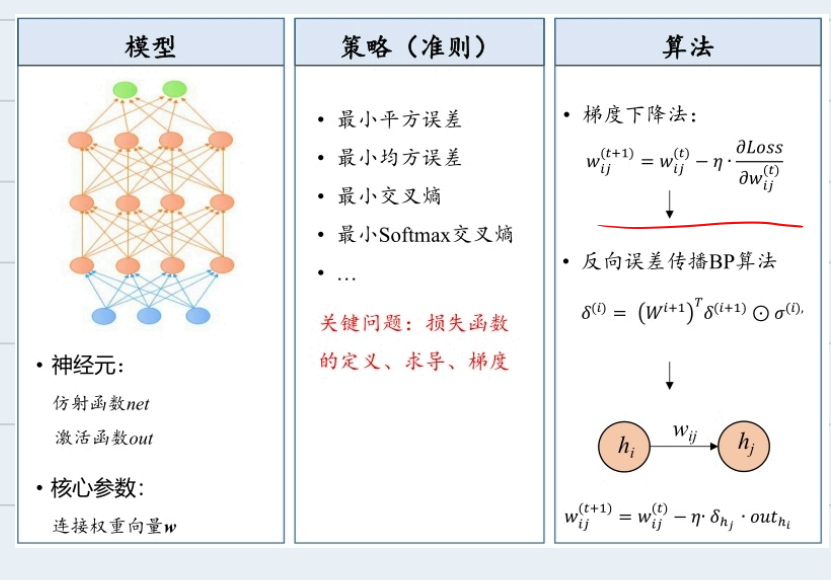

模型	策略（准则）	算法
• 神经元: 仿射函数net 激活函数out • 核心参数: 连接权重向量w	• 最小平方误差 • 最小均方误差 • 最小交叉熵 • 最小Softmax交叉熵 • … 关键问题: 损失函数的定义、求导、梯度	• 梯度下降法: $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta\frac{\partial Loss}{\partial w_{ij}^{(t)}}$ • 反向误差传播BP算法 $\delta^{(l)} = (W^{(l+1)})^T\delta^{(l+1)} \odot \sigma'^{(l)}$ $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta \cdot \delta_{h_j} \cdot out_{h_i}$

自适应:

十章 卷积、求: 影响因素 < 核、大小 步长

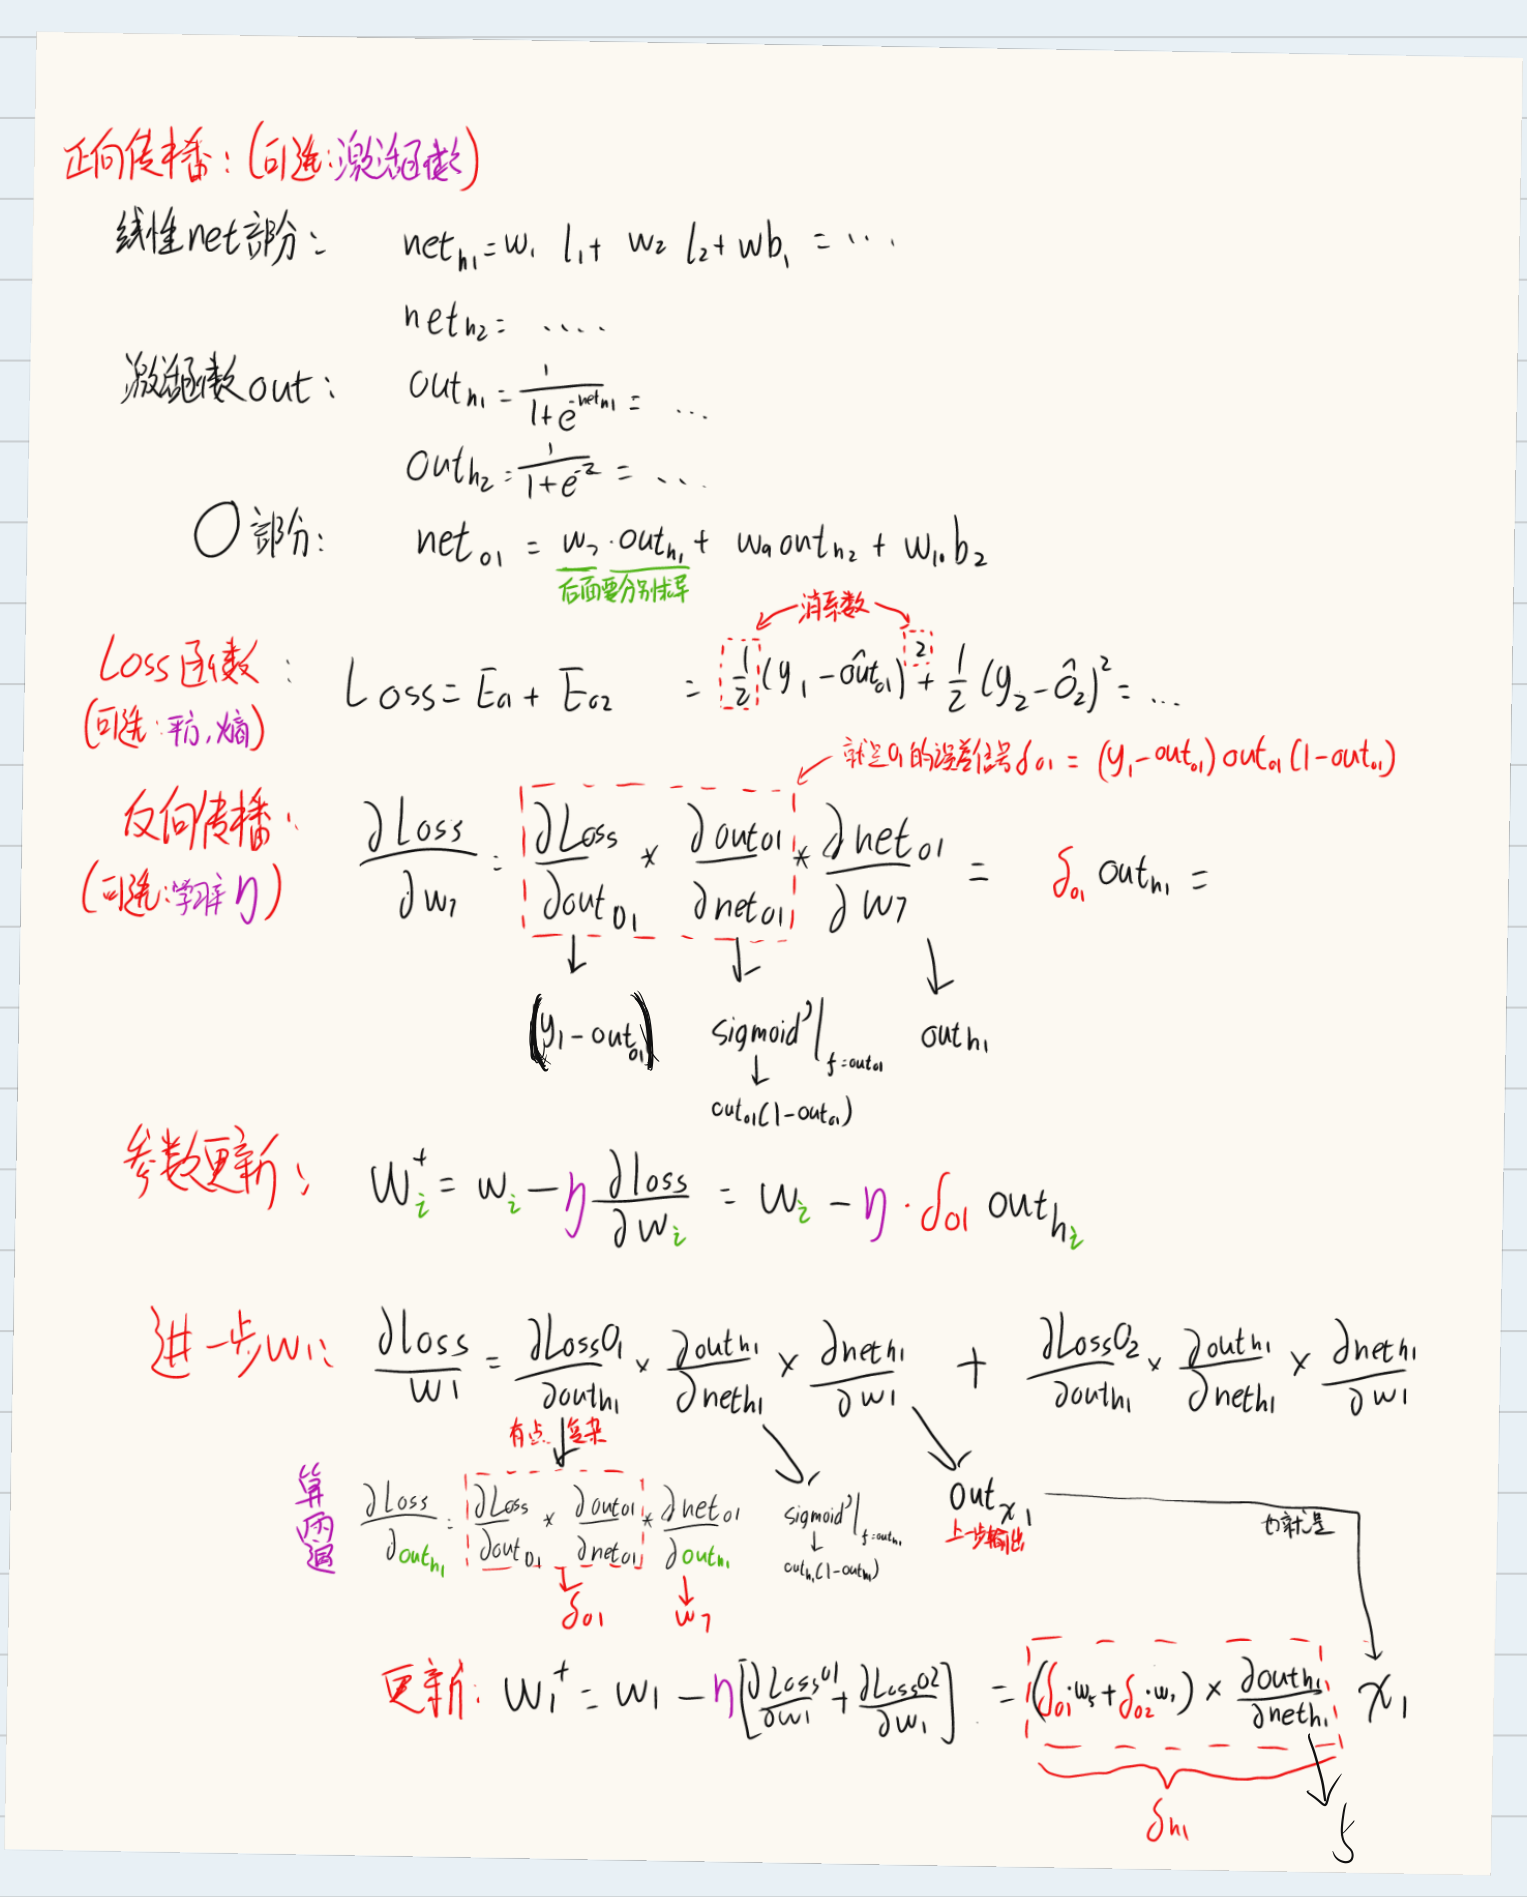

正向传播: (可选: 激活函数)

线性net部分: $net_{h_1} = w_1 l_1 + w_2 l_2 + w b_1 = \ldots$
$net_{h_2} = \ldots$

激活函数out: $out_{h_1} = \frac{1}{1+e^{-net_{h_1}}} = \ldots$
$out_{h_2} = \frac{1}{1+e^{-z}} = \ldots$

O部分: $net_{o_1} = w_7 \cdot out_{h_1} + w_8 out_{h_2} + w_1 b_2$ 后面要分别求导

Loss函数 (可选: 平方, 熵): $Loss = E_{o1} + E_{o2} = \frac{1}{2}(y_1 - \hat{out}_{o1})^2 + \frac{1}{2}(y_2 - \hat{o}_2)^2 = \ldots$ 消系数

反向传播 (可选: 学习率 η): $\frac{\partial Loss}{\partial w_7} = \frac{\partial Loss}{\partial out_{o1}} \times \frac{\partial out_{o1}}{\partial net_{o1}} \times \frac{\partial net_{o1}}{\partial w_7} = \delta_{o1} out_{h_1} =$
就是O₁的误差信号 $\delta_{o1} = (y_1 - out_{o1})out_{o1}(1 - out_{o1})$
$(y_1 - out_{o1})$ sigmoid'$|_{f=out_{o1}}$ → $out_{o1}(1-out_{o1})$ out_{h_1}

参数更新: $W_i^+ = w_i - \eta\frac{\partial loss}{\partial w_i} = W_i - \eta \cdot \delta_{o1} out_{h_i}$

进一步w₁: $\frac{\partial loss}{w_1} = \frac{\partial Loss_{O_1}}{\partial out_{h_1}} \times \frac{\partial out_{h_1}}{\partial net_{h_1}} \times \frac{\partial net_{h_1}}{\partial w_1} + \frac{\partial Loss_{O_2}}{\partial out_{h_1}} \times \frac{\partial out_{h_1}}{\partial net_{h_1}} \times \frac{\partial net_{h_1}}{\partial w_1}$
有点复杂 sigmoid'$|_{f=out_{h_1}}$ → $out_{h_1}(1-out_{h_1})$ out_{x_1} 上一步输出 也就是

算两遍 $\frac{\partial Loss}{\partial out_{h_1}} = \frac{\partial Loss}{\partial out_{o1}} \times \frac{\partial out_{o1}}{\partial net_{o1}} \times \frac{\partial net_{o1}}{\partial out_{h_1}}$ → δ_{o1} w_7

更新: $W_1^+ = w_1 - \eta\left[\frac{\partial Loss_{o1}}{\partial w_1} + \frac{\partial Loss_{o2}}{\partial w_1}\right] = \underbrace{(\delta_{o1} \cdot w_5 + \delta_{o2} \cdot w_7) \times \frac{\partial out_{h_1}}{\partial net_{h_1}}}_{\delta_{h_1}} x_1$